摘要

随着工程教育专业认证（EAC）与成果导向教育（OBE）理念的深入推进，高校在开展专业建设与质量评估过程中产生了大量结构复杂的文档资料，如培养方案、课程教学大纲及达成度分析报告等。这类文档具有信息密集、结构复杂及证据链分散等特点，传统基于人工查阅的方式效率低下，且难以保证信息溯源的准确性。针对上述问题，本文设计并实现了一种基于检索增强生成（Retrieval-Augmented Generation, RAG）框架的工程认证私有知识助手系统。

在数据处理方面，本文采用语义感知切块（Semantic Chunking）方法对工程认证文档进行结构化处理，并为文本块绑定文件路径与页码等元数据，以支持证据链溯源。在检索机制方面，构建了“初筛—精排”的双阶段检索框架：首先基于 `bge-m3` 模型进行稠密向量检索以保证候选覆盖率，随后利用 `bge-reranker-v2-m3` 进行重排序，以提升候选文本的相关性。在生成阶段，设计了基于提示工程的约束机制，要求大模型仅基于检索内容进行回答并输出引用信息，从而降低幻觉风险并增强结果的可解释性。

在系统实现上，基于 Vue、LangChain 与向量数据库构建了完整的工程系统，并实现了证据链可视化功能。实验结果表明，所提出方法在检索排序质量（MRR）及生成结果相关性方面均有所提升；同时，证据链相关指标显著提高，其中引用准确率与溯源成功率分别由 0.02 提升至 0.76 和 0.90，验证了系统在工程认证场景下的有效性与实用性。

综上，本文所提出的工程认证私有知识助手系统能够在保证检索效率的同时提升生成结果的可靠性与可追溯性，为复杂工程文档的智能化管理提供了一种可行方案。

关键词：检索增强生成；工程教育认证；双阶段检索；重排序；提示工程；证据链溯源

目　录

1　绪论 4

1.1　研究背景 4

1.2　研究意义 4

1.3　国内外研究现状 5

1.3.1　国外研究现状 5

1.3.2　国内研究现状 5

1.4　研究主要内容与预期目标 6

1.4.1　研究主要内容 6

1.4.2　预期目标 7

2　相关理论与核心技术基础 7

2.1　大规模语言模型与提示工程 7

2.1.1　大语言模型 (LLM) 理论基础 7

2.1.2　提示工程 8

2.1.3　基于上下文的约束提示与幻觉抑制 8

2.2　检索增强生成（RAG）技术原理 8

2.2.1　RAG 的基本定义与核心价值 8

2.2.2　RAG 的标准执行范式 9

2.2.3　技术演进：从 Naive RAG 到 Advanced RAG 9

2.3　向量数据库与检索技术 10

2.3.1　文本向量化表示（Embedding）原理 10

2.3.2　相似度计算机制 10

2.3.3　向量数据库与 ANN 算法 10

2.4　工程教育专业认证与 OBE 理念 11

2.4.1　工程教育专业认证的背景与目的 11

2.4.2　成果导向教育（OBE）的核心内涵 11

2.4.3　业务痛点关联：证据链管理与溯源挑战 11

3　知识助手系统需求分析与总体设计 12

3.1　系统需求分析 12

3.1.1　功能性需求分析 12

3.1.2　非功能性需求分析 13

3.2　系统总体架构设计 14

4　核心模块设计与对比实验分析 16

4.1　复杂结构文档解析与精细化切块策略 16

4.1.1 解析引擎选型与 Benchmark 验证 16
4.1.2 语义感知与精细化切块策略 17
4.2 领域知识向量化与 Embedding 模型选型 17
4.2.1 评测基准与选型约束条件 18
4.2.2 榜单筛选与候选模型确定 18
4.2.3 本地测试集验证与最终选型 19
4.3 混合检索与重排序（Re-ranking）机制 20
4.3.1 单阶段稠密检索的局限性分析 20
4.3.2 双阶段检索框架设计 20
4.4 提示工程设计与生成约束 21
4.4.1 基于检索约束的生成机制 22
4.4.2 系统级 Prompt 约束设计 22
4.4.3 证据驱动的引用生成机制 22
4.4.4 幻觉抑制机制分析 23
4.4.5 与系统证据链机制的协同作用 23

5 系统实现与整体性能评测 23
5.1 开发环境与系统部署 23
5.2 核心功能模块实现与界面展示 24
5.3 端到端系统整体性能评估 25

6 总结与展望 27
6.1 全文工作总结 27
6.2 系统局限性与未来展望 27

1 绪论

1.1 研究背景

大规模语言模型（LLM）自 Transformer 架构问世以来，凭借其在自然语言理解、上下文推理和文本生成等方面的卓越表现，已成为人工智能领域最具革命性的技术之一。LLM 在通用知识问答、摘要生成和代码辅助等知识密集型任务中的应用潜力获得了广泛认可。

然而，由于 LLM 的知识本质上是隐式存储于其数千亿级的参数之中，这种参数化记忆模式存在固有的挑战：首先，模型的知识库是静态且有时效性限制的，难以应对日新月异的实时信息；其次，LLM 在处理复杂或低频知识时，极易出现“幻觉”（Hallucination）现象，即生成看似合理但事实上错误或虚构的内容[1]；更关键的是，其推理过程是一个“黑箱”，缺乏透明性和可溯源性，这对于需要严格证据链支撑的垂直应用场景是不可接受的[2]。

为了克服这些局限性，检索增强生成（Retrieval-Augmented Generation, RAG）框架应运而生。RAG 代表了一种范式创新，它将 LLM 的内在（参数化）知识与庞大、动态的外部（非参数化）知识库进行协同融合。其核心机制是在 LLM 生成答案之前，通过智能检索器从外部数据库中提取最相关的证据或文档片段，并将这些证据作为上下文输入给 LLM 进行条件生成。RAG 框架通过这种“先检索，后生成”的方式，有效地解决了知识时效性、幻觉和透明度问题，从而保证了模型回答的高准确性、知识的实时性和证据链的可溯源性。这使得 RAG 成为将 LLM 安全、精准地引入到对可信赖性有极高要求的垂直领域的关键技术。

1.2 研究意义

本研究的特定背景为高校工程教育专业认证（EAC）工作，其核心理念是成果导向教育（OBE)[3-4]。该工作具有知识密度高、文档类型复杂（如课程大纲、试卷、学生报告、自评报告等海量私有文档）、以及对证据链完整性和溯源精准度有极高监管要求的特点。传统的认证工作流程高度依赖人工查阅，不仅耗费大量时间精力，且极易导致证据链遗漏或断裂，严重影响认证效率和质量。

基于此，设计并实现一个基于检索增强生成（RAG）框架的智能知识助手系统，以提供一个安全、精准、可追溯的工程认证知识服务平台，具有重要的现实意义：

- **提升认证工作效率**：通过提供标准查询、证据链溯源等功能，能够帮助认证人员快速定位关联证据，显著缩短查阅时间，提升效率和准确度。
- **保障认证质量与促进持续改进**：系统能够确保证据链的完整且准确[4]，降低人为失误风险，同时支持对知识关联性的深度挖掘，辅助专业建设持续改进。

- **私有知识的安全与便捷管理**：利用向量数据库和 RAG 框架，可实现对海量分散私有文档的统一管理和高效检索，将文档转化为可被高效访问的知识资产。

1.3 国内外研究现状

1.3.1 国外研究现状

国外研究在大型语言模型的知识增强、向量数据库构建以及 RAG 性能优化方面处于理论和技术的前沿，为本领域提供了坚实的底层基础。

检索增强生成（RAG）框架的提出是解决 LLM 知识局限性的关键突破。Lewis 等（2020）[2] 开创性地提出了 RAG 模型，将预训练的 Seq2Seq 模型与可微分的外部非参数记忆相结合，证明了该模型能够显著提升 LLM 在知识密集型任务上的性能，同时解决了 LLM 决策不可溯源的问题，为模型的生成结果提供了证据来源（provenance）（见[2] Abstract）。在此基础上，Gao 等（2024）[1] 系统地将 RAG 的发展划分为 Naive RAG、Advanced RAG 和 Modular RAG 三个阶段（见[1] Abstract），并强调 Advanced RAG 范式致力于对"检索、增强、生成"这三个核心环节进行全面、精细化的优化，是当前研究的主流方向。

支撑 RAG 框架核心检索功能的是向量数据库（VDB）。Taipalus（2024）[5] 和 Ma 等（2025）[6] 的研究均指出，VDB 的出现是为了管理传统数据库难以处理的高维向量数据，并已成为现代 AI 系统中的关键组件，广泛应用于相似性搜索和智能问答系统（见[5] Abstract,[6] Abstract）。孙雨生和曾俊皓（2024）[7] 进一步细化了 VDB 的关键技术，包括向量数据的嵌入生成、索引和检索（见[7] 结果/结论）。为了实现 VDB 的高性能检索，高效的近似最近邻（ANN）搜索算法至关重要。其中，Jégou 等（2011）[8] 提出的乘积量化（Product Quantization, PQ）算法，通过将高维空间分解并进行量化，是实现大规模向量索引和检索，同时兼顾速度和内存效率的核心技术之一（见[8] Abstract）。此外，针对工程认证文档这类复杂、长篇的文本，RAG 面临检索不准确和上下文碎片化的挑战，Luo 等（2025）[9] 提出了 RetroLM 框架，创新性地引入了 KV-level 检索增强机制（见[9] Abstract），通过在 LLM 的键值缓存（KV Cache）层面进行检索，显著提高了模型对检索结果的有效利用率，为本课题处理复杂的长文档关联性问题提供了技术参考。

1.3.2 国内研究现状

国内研究主要聚焦于 RAG 技术的实践应用和工程教育领域的核心理论探讨，为本课题的应用场景和优化方向提供了实践经验和理论基础。

在 RAG 应用实践方面，国内研究已将 RAG 技术成功应用于企业客服和垂直知识问答系统。例如，张丽静等（2024）[10] 在智能客服系统中的研究，验证了基于 LLM 和 RAG 实现智能客服的可行性，并强调系统在实际应用中必须具备可溯源性和安全

性（见[10] 摘要）。同时，冯腾发（2025)[11] 对 RAG 知识库在低资源领域的应用进行了深入研究，实践证明 RAG 系统的性能高度依赖于文档切块策略和检索增强技术的选择，这为本课题的系统调优提供了经验指导（见[11] 引言/正文）。

本课题的应用领域对知识的权威性、精准性和证据链的完整性要求极高。在工程教育领域的核心理念方面，李志义（2014)[3] 详细解析了工程教育专业认证的核心——成果导向教育（OBE）理念，强调教育目标应以“学生毕业时应达到的能力和成果”为导向（见[3] 第一段）。而林健（2015)[4] 则进一步指出，认证工作的关键挑战在于对证据链条的高效管理和准确溯源，即如何可靠地证明课程目标与毕业要求之间的关联是完整且有效的（见[4] 英文摘要）。针对工程认证文档条款间语义耦合性强、证据链条复杂的特点，孙如玉等（2025)[12] 提出了 HSR-RAG（层级语义递归 RAG），该方法通过建立基于文档结构特征的多级语义解析模型和递归式语义聚合算法，有效解决了标准文本处理中存在的知识碎片化与语义关联弱化等局限性（见[12] 摘要），为本课题设计 OBE 导向的结构化切块策略提供了关键的技术思路。

1.4 研究主要内容与预期目标

1.4.1 研究主要内容

(1) 基于结构化感知的复杂文档解析与知识库构建。针对工程认证中涉及的海量多模态非结构化文档（如培养方案、自评报告、教学大纲等），本文将重点探讨基于文档逻辑结构的语义切块（Chunking）策略，以克服传统固定字符切分导致的语义破损问题。同时，通过设计对比实验，定量分析不同解析工具在处理复杂表格、跨页段落及多级标题时的提取准确度，最终构建一个支持结构化感知的高质量本地私有知识库。

(2) 面向工程认证领域的向量化检索与重排序机制设计。为满足工程教育特定术语（如“毕业要求指标点”、“OBE”等）的精准语义匹配需求，本文将引入适合该垂直领域的 Embedding 模型，并构建专属测试集（Golden Dataset）对主流中英文 Embedding 模型进行交叉评估。在检索策略设计上，本文采用“初筛-精排”的双阶段架构：首先通过稠密向量（Dense Vector）检索召回初步相关的文档块；随后，引入基于 bge-reranker-v2-m3 的 Cross-Encoder 重排序（Re-ranking）机制，对初筛结果进行深度的语义交互计算与重新打分，从而最大化最终输入给大模型的上下文精准度，并有效滤除噪声干扰。

(3) 大模型接入与生成约束（提示工程）。系统后端将基于 LangChain 框架接入高性能大语言模型（如 DeepSeek API），打通 RAG 核心链路。针对工程认证工作对严谨性的极高要求，本文专门设计了面向 OBE 理念的提示词（Prompt）模板，强制约束模型仅依据检索召回的上下文进行应答。旨在有效抑制大模型的“幻觉”现象，确保生成内容的真实性与逻辑一致性。

(4) 系统工程化部署与证据溯源实现。在前端展示层面，采用 Vue 框架开发知识

助手的 Web 交互界面，完成系统的整体工程化部署。该模块设计的核心聚焦于“可追溯性”，通过开发证据链可视化功能，确保系统生成的每一条回答均能提供精确的引用链接，支持用户一键跳转至原始文档的对应段落与页码，从而为认证专家的核查工作提供无缝的证据支撑。

1.4.2 预期目标

- 完成原型系统开发：成功搭建一套基于 Advanced RAG 架构的工程教育认证知识助手（Vue + DeepSeek API），支持自然语言流畅交互与私有文档的高效管理。
- 实现高精度知识检索：通过双阶段检索与重排序优化，显著提升系统在处理“课程目标”、“达成度计算”等高频专业问题时的检索准确率（Recall 与 Precision 指标达到预期基准）。
- 确保证据链精准溯源：生成的问答结果必须具备高度的可解释性，实现精准的“证据闭环”，杜绝事实性编造。
- 提升认证业务效率：验证系统在实际业务场景中的可用性，证明其相较于传统人工翻阅方式能大幅缩短信息比对与检索时间，有效赋能教学管理人员高质量完成认证材料的整编工作。

2 相关理论与核心技术基础

2.1 大规模语言模型与提示工程

2.1.1 大语言模型 (LLM) 理论基础

大规模语言模型（Large Language Models, LLM）是构建于 Transformer 架构之上的深度神经网络模型，通过在海量文本语料上进行预训练，展现出卓越的自然语言理解（NLU）与生成（NLG）能力。LLM 的核心机制在于其集成的自注意力机制（Self-Attention），该机制赋予了模型捕捉长距离词项依赖关系的能力，使其能够深入理解复杂的语义结构并在生成文本时保持高度的上下文连贯性[13]。

尽管 LLM 在通用任务中表现优异，但其知识存储依赖于预训练阶段形成的“参数化记忆”。这种模式导致模型存在固有的局限性：一方面，模型无法实时更新预训练截止日期之后的知识，产生“知识滞后”现象；另一方面，在处理专业性极强或长尾领域的知识密集型任务时，模型极易因内蕴知识匮乏而产生“幻觉（Hallucination）”，即生成看似逻辑合理但违背事实或虚假的内容[10]。

2.1.2 提示工程

提示工程是指通过设计、优化和精炼输入给大模型的文本（Prompt），以引导模型展现出特定能力并约束其输出行为的技术范式。在不改变模型权重参数的前提下，提示工程作为连接用户意图与模型生成能力的桥梁，决定了 LLM 在特定应用场景下的表现上限。有效的提示设计通常由指令（Instruction）、上下文背景（Context）和输出约束（Constraint）等要素构成，旨在将模型的通用推理能力锚定在特定的任务框架内。

2.1.3 基于上下文的约束提示与幻觉抑制

在知识问答系统中，缓解模型幻觉的关键技术路径在于基于上下文的约束提示（Context-Augmented Prompting）。其理论核心是将模型的工作模式从“基于检索的生成”转变为“基于给定知识的阅读理解”，即通过将检索到的外部非参数化知识（如专业文档片段）注入到提示词中，为模型提供即时的参考依据[1]。

研究表明，通过以下特定提示策略可以显著抑制幻觉现象：

1. **角色设定（Persona Prompting）**：在提示词中明确设定模型作为专业领域专家（如工程认证专家）的身份，促使模型进入更严谨的推理模式。
2. **上下文注入与指引**：明确告知模型“以下是相关的参考文档”，并将检索到的文本块作为事实边界提供给模型。[1]。
3. **严格负约束（Negative Constraints）**：通过在指令中加入如“仅依据提供的上下文回答”、“如果信息不足，请回答不知道而非自行编造”等排他性约束，强制限制模型的发散性思维，从根本上缓解事实性错误的产生。

这种基于上下文的约束机制能够有效地将 LLM 的推理范围限定在可验证的证据链内，从而大幅降低事实性错误的产生概率，确证输出内容的专业性与真实性。

2.2 检索增强生成（RAG）技术原理

2.2.1 RAG 的基本定义与核心价值

检索增强生成（Retrieval-Augmented Generation, RAG）是一种结合了预训练生成模型（参数化记忆）与外部知识库（非参数化记忆）的混合范式[1-2]。大规模语言模型（LLM）虽然在自然语言理解上表现卓越，但由于其知识隐式存储于静态的权重参数中，面临着显著的局限性：一是“知识滞后”问题，LLM 无法获取训练截止日期之后的实时信息；二是“幻觉（Hallucination）”现象，即模型在处理长尾知识或复杂事实时易生成虚假内容[1-2]。

研究表明，RAG 通过在生成环节前引入检索机制，强制模型依据外部可信证据进行回答，从而有效抑制了事实性错误[1-2]。这种“开卷考试”式的运作模式，不仅增

强了回答的准确性，还为模型的决策过程提供了可追溯的证据链，实现了从“黑箱推理”向“透明论证”的转变[1-2]。

2.2.2 RAG 的标准执行范式

根据 Lewis 等人的研究，RAG 的标准处理流程可概括为索引（Indexing）、检索（Retrieval）与生成（Generation）三个核心阶段：

1. **索引阶段（Indexing）**：这是知识库构建的基础。首先对多模态原始文档进行清洗与提取，将其转化为统一的纯文本格式；随后利用文本分割技术将长文档切分为语义完整的文本块（Chunks）；最后通过嵌入模型（Embedding Model）将文本块映射为高维向量，并存储于向量数据库（Vector Database）中，以支持后续的相似度计算[1,6]。
2. **检索阶段（Retrieval）**：当接收到用户查询（Query）时，系统利用相同的嵌入模型将查询请求向量化。通过最大内积搜索（MIPS）或余弦相似度算法，从数据库中匹配出与该查询语义距离最近的 Top-K 个文本块.[2]这一过程实质上是从海量数据中召回最相关的上下文信息。
3. **生成阶段（Generation）**：检索到的文本块与用户的原始查询被共同喂入提示词模板（Prompt Template），引导 LLM 在既定上下文约束下组织语言，生成最终答案[1-2]。在该阶段，参数化记忆与非参数化知识协同工作，确保输出内容既具备自然语言的流畅性，又具备事实的准确性。

2.2.3 技术演进：从 Naive RAG 到 Advanced RAG

随着研究的深入，RAG 技术已从最初的朴素模式（Naive RAG）演进至高级架构（Advanced RAG)[1] 。Naive RAG 主要依赖简单的“检索-阅读”链路，但在实际应用中暴露出检索精度不足、召回内容噪声干扰严重以及 LLM 处理长上下文时易产生“中间丢失（Lost in the Middle）”等痛点[9]。

为克服上述问题，Advanced RAG 引入了更为复杂的优化机制。其核心演进逻辑在于从单一检索转向“初筛-精排”的双阶段检索架构：

- **初筛（Recall）阶段**：系统采用混合检索策略，结合了基于关键词的稀疏检索（如 BM25）与基于语义的稠密向量检索。前者擅长专有名词的精确匹配，后者擅长语义理解，二者的结合显著提升了相关文档的召回率[1-2]。
- **重排序（Re-ranking）阶段**：在初筛阶段召回大量文档块后，引入基于 Cross-Encoder 的重排序模型。重排序器会对召回的文档块与用户问题进行更深层的语义关联度打分并重新排序，滤除其中的不相关噪声数据。这一机制确保了输入 LLM 的上下文是最具针对性的证据，有效减轻了无关噪声对模型生成的误导[1]。

2.3 向量数据库与检索技术

2.3.1 文本向量化表示（Embedding）原理

在处理大规模非结构化数据时，文本向量化（Embedding）是实现机器理解语义的核心技术。其基本原理是通过深度学习模型将离散的文本符号映射至一个连续的高维向量空间中，生成高维稠密向量（Dense Vector）[6] 。与传统的稀疏表示方法不同，稠密向量能够将语义信息压缩在有限的维度中（通常为 768 或 1024 维），从而有效地捕获词项间的上下文关联与深层语义特征[5-6]。

这种表示方法的优势在于它实现了“语义距离”向“空间距离”的转化。在向量空间中，语义相近的文本块由于具有相似的特征分布，其对应的向量在空间位置上会彼此接近[5,7] 。这种机制不仅解决了关键词匹配无法处理同义词、近义词的局限性，还为后续基于数学度量的知识检索奠定了表征基础。

2.3.2 相似度计算机制

在完成文本的向量化表示后，衡量两个向量在空间中的相关性成为检索的关键。在众多的距离度量指标中，余弦相似度（Cosine Similarity）被广泛应用于自然语言处理任务中[5]。余弦相似度通过计算两个向量之间夹角的余弦值来衡量它们的方向一致性，其取值范围在 [-1, 1] 之间，值越接近 1 则代表两个向量的语义相关性越高，而忽略其绝对模长的差异。

除了余弦相似度外，常见的度量方式还包括欧式距离（L2 Distance）和内积（Inner Product）[5-6]。对于归一化后的向量，这几种度量方式在排序结果上具有等价性。以余弦相似度为例，其数学计算公式如下所示：

$$\text{similarity} = \cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\|\|\mathbf{B}\|} = \frac{\sum_{i=1}^{n} A_i B_i}{\sqrt{\sum_{i=1}^{n} A_i^2}\sqrt{\sum_{i=1}^{n} B_i^2}} \tag{1}$$

通过上述公式，系统能够量化查询向量与知识库中文档向量的匹配程度，并按分值高低进行排序召回[7]。

2.3.3 向量数据库与 ANN 算法

向量数据库（Vector Database, VDB）如 Milvus 和 Chroma，是专为存储、管理和高效检索大规模高维向量而设计的专用系统[6] 。在小规模数据集下，可以使用精确的最邻近搜索（K-Nearest Neighbor, KNN）通过暴力扫描（Brute-force）计算所有距离。然而，由于向量检索面临“维度灾难”，当数据量达到百万级甚至亿级时，KNN 的时间复杂度 O(nD) 将导致检索延迟无法满足实时应用的需求[8]。

为了在检索速度与精度之间取得平衡，向量数据库普遍采用近似最近邻搜索（Approximate Nearest Neighbor, ANN）算法[8] 。ANN 通过预先构建索引结构（如 HNSW

图索引或倒排索引），将搜索范围限制在空间的一个子集中，从而实现毫秒级的响应。

其中，乘积量化（Product Quantization, PQ）是一种极具代表性的有损压缩与索引算法[8]。PQ 的核心思想是将高维空间分解为多个低维子空间的笛卡尔积，并对每个子空间分别进行聚类量化。这种方法不仅大幅压缩了向量的存储空间，还允许系统在不解压原向量的情况下，通过查表操作快速估算近似距离，显著提升了大规模向量库的检索能效[6]。

2.4 工程教育专业认证与 OBE 理念

2.4.1 工程教育专业认证的背景与目的

工程教育专业认证（Engineering Education Accreditation, EAC）是由非政府、非盈利的第三方组织对工程技术领域专业进行的正式认可，旨在评价其教育质量是否达到行业公认的最低合格标准[4]。随着我国正式加入《华盛顿协议》，具有国际实质等效性的专业认证已成为推动高等工程教育改革的关键抓手[3]。认证的核心目的在于进一步提高工程教育质量，增强人才培养对经济社会发展的适应性，并最终实现工程教育的国际互认，提升毕业生的国际竞争力[4]。

2.4.2 成果导向教育（OBE）的核心内涵

工程教育认证遵循“成果导向（Outcome-Based Education, OBE）”、“以学生为中心”和“持续改进”三大核心理念，其中 OBE 理念被视为整个认证体系的灵魂。OBE 指出，教学设计与实施的目标应聚焦于学生通过教育过程最终取得的学习成果（Learning Outcomes），而非单纯的知识积累。

在实践中，OBE 强调“反向设计”原则：由外部需求决定培养目标，由培养目标决定毕业要求，再由毕业要求决定课程体系。其中，“毕业要求”是对学生毕业时应掌握的知识、能力和素质的具体描述，而“课程目标”则是支撑毕业要求的最小执行单元。这种严密的映射关系要求课程体系中的每一门课程必须对实现特定的毕业要求有确定的贡献，从而确保全体学生在完成学业时均能达到预期的顶峰成果。

2.4.3 业务痛点关联：证据链管理与溯源挑战

尽管 OBE 理念提供了严谨的逻辑框架，但在实际的认证业务与自评报告撰写过程中，高校面临着严峻的挑战。认证体系要求专业必须通过“举证”的方式，严谨地回答每一项毕业要求是如何实现的，以及如何评价其实际效果。这意味着认证工作不仅涉及教学大纲、培养方案等制度性文件，还包含海量的教学过程性文档，形成了一个庞杂且语义耦合极强的非结构化文档体系[3-4]。

在传统的文档管理模式下，由于各条款与证据点之间存在复杂的多对多映射关系，人工进行“毕业要求—课程模块—课程目标”的逻辑校验与证据核查效率极低，且

难以确保证据链条的完整性与准确溯源。当专家进行现场考查或审核自评报告时，对“证据链条的高效管理和准确溯源”提出了实时化、精准化的极高要求。这种对海量文档语义理解与证据自动定位的刚性需求，暗示了传统人工治理方式已难以支撑 OBE 理念的深度落地，急需引入智能化手段实现知识的精准检索与可靠证成。

3 知识助手系统需求分析与总体设计

3.1 系统需求分析

工程教育专业认证（EAC）的核心理念是成果导向教育（OBE），其认证过程具有知识密度高、文档类型复杂以及对证据链完整性和溯源精准度要求极高的行业特征。传统的认证工作流程高度依赖人工查阅海量分散的私有文档，极易导致证据链遗漏或断裂，严重影响认证效率和质量。为突破这一业务瓶颈，本系统以解决 EAC 认证工作中的实际痛点为导向，结合大语言模型（LLM）与检索增强生成（RAG）技术，进行详尽的系统需求分析。

3.1.1 功能性需求分析

为构建安全、精准、可追溯的工程认证知识服务平台，有效辅助教学管理人员进行自评报告撰写和材料整编，本系统需满足以下核心功能性需求：

1. **私有文档库管理与解析需求**工程认证工作涉及的私有文档往往篇幅较长且类型复杂（如专业培养方案、教学大纲、课程目标达成度报告、学生试卷及自评报告等）。系统必须具备对这些海量分散的私有文档进行统一管理和高效转化的能力。
   - **多模态复杂文档导入**：系统需支持 PDF、Word 等多模态与多格式文档的批量导入与预处理清洗。
   - **结构化解析与语义切分**：针对传统固定字符数切分（Fixed-size chunking）容易导致表格、跨页段落或“毕业要求指标点”等逻辑条目语义破损的问题，系统需支持基于文档层级特征的结构化解析与语义感知切片（Chunking），提取并保留文档的层级结构信息与完整语境。
   - **向量化存储**：系统需支持将解析后的非结构化文本通过嵌入模型（Embedding）转化为高维向量，并存储于本地私有向量数据库（如 Milvus 或 Chroma）中，将离散文档转化为可被高效访问的知识资产。
2. **智能问答与专业意图理解需求**认证工作参与人员需要通过系统快速获取高度专业化的信息。系统不仅需要具备通用的自然语言处理能力，更需要针对工程教育领域的特定语境进行深度适配。

- **自然语言交互**：系统需提供友好的 Web 端交互界面，支持用户以自然语言的形式输入查询问题。
- **专业意图精准理解**：针对通用大模型在处理工程认证特定领域术语时匹配度不高（即长尾与噪声问题），系统需能精准识别并理解“毕业要求指标点”、“课程目标达成度”、“成果导向教育（OBE）”等特定专业术语的语义关联。

3. **证据链可视化与精准溯源需求**工程教育认证工作对“证据链”的完整性与真实性具有极高的监管要求。由于大语言模型存在固有“幻觉”（Hallucination）缺陷，其黑箱推理过程对于需要严格证据支撑的垂直应用场景是不可接受的。因此，系统必须建立严密的证据倒查机制：
   - **引文参考输出**：系统在输出最终回答时，绝不能仅提供单一的总结性文本，必须强制同步输出其参考的引文片段与支撑依据。
   - **特定段落与页码级溯源**：必须赋予系统高度的“可解释性”与“可溯源性”。系统需支持溯源可视化功能，当认证专家或用户点击回答中的引文标注时，系统需能够直接跳转并精准定位至原始文档（如 PDF）的具体页码与特定段落。这一需求是辅助专家无缝进行证据核查、确保证据链闭环的核心支撑。

3.1.2 非功能性需求分析

在满足上述业务功能的基础上，系统还需在性能、安全性与可维护性方面达到以下非功能性指标：

1. **准确性与安全性需求**大语言模型在生成过程中存在固有的“幻觉”缺陷，其黑箱推理极易生成看似合理实则错误的内容，这对于需要严格证据支撑的工程认证场景是不可接受的。系统必须通过严格的提示工程（Prompt Engineering）进行约束，确保大模型的回答完全忠实于本地检索到的私有文档，彻底杜绝事实性编造。同时，系统需保障本地化部署架构的数据安全，防止高校核心教务数据的外泄。
2. **系统性能与响应效率需求**为保障知识助手的交互体验，系统整体响应延迟需控制在合理范围内。由于本系统在检索环节采用了复杂度较高的双阶段检索架构（即稠密向量初筛检索与重排序精排机制），且大模型的长文本生成需要一定算力开销，系统必须在检索高召回率与计算速度之间取得良好平衡，确保端到端的问答延迟能够满足用户的日常流畅使用。
3. **系统的可扩展性与易用性需求**
   - **易用性**：系统需具备友好的 Web 端交互界面（基于 Vue 框架构建），保证页面布局直观、交互操作简便，降低非技术背景教务人员的学习门槛。

- **可扩展性**：考虑到各专业的培养标准与认证材料每年都会进行滚动更新，系统的底层架构设计必须方便后续私有知识库的动态更新、文档扩容及索引热重载，以长效支撑高校工程教育的持续改进机制。

3.2 系统总体架构设计

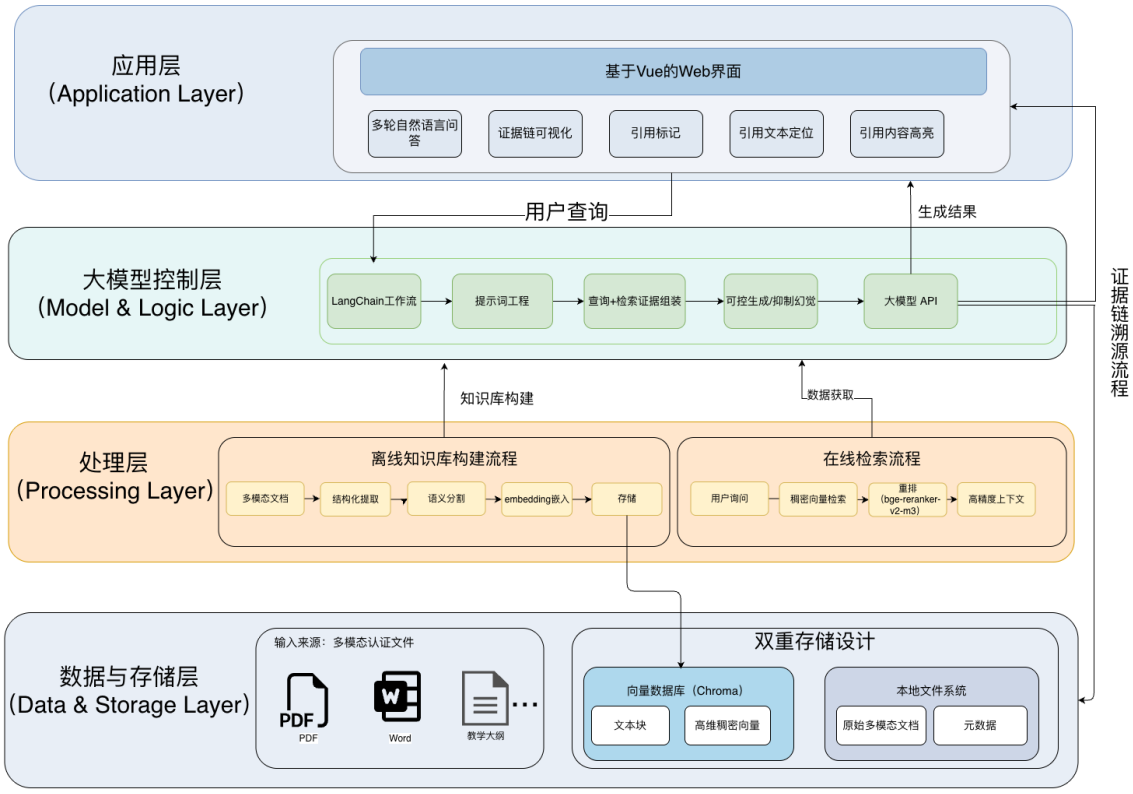

图 1: 基于 RAG 的工程教育认证系统总体架构图

1. **数据与存储层 (Data & Storage Layer)**：

   本层是系统的底层数据底座与物理存储介质，主要负责多源异构数据的持久化管理。系统底层的数据来源主要涵盖工程教育专业认证（EAC）工作中的各类私有多模态复杂文档，如专业培养方案、教学大纲、课程目标达成度报告及学生试卷等（通常涉及 PDF、Word 等格式）。在核心存储组件设计上，系统采用“双轨并行”的混合存储架构：一方面，采用专门的高性能向量数据库（如 Milvus 或 Chroma）来持久化存储经过解析与语义切分后的文本块（Chunks）及其对应的高维稠密向量，从而将海量离散文档转化为可被高效访问的机器可读知识资产；另一方面，系统利用本地文件系统（Local File System）持久化归档原始多模态文档与结构化元数据（Metadata）。这种存储策略不仅支撑了高效的向量近邻搜索，更为后续前端的应用层实现“证据链精准溯源与页码定位”提供了坚实的物理文件支撑。

2. **核心处理层 (Processing Layer)**：

本层作为检索增强生成（RAG）架构的引擎中枢，承担着离线私有知识库构建与在线智能检索的双重核心任务。在离线知识库构建阶段，针对工程认证文档长文本、多表格等结构复杂的特征，系统引入了基于文档层级特征的结构化解析与语义感知切块（Semantic Chunking）技术[1]。该方法有效克服了传统固定字符粗粒度切分导致的表格破损与跨页语义断裂问题，最大程度保留了“毕业要求指标点”等核心条款的完整上下文语境。在在线检索机制设计上，本系统全面拥抱 Advanced RAG 理念，构建了高精度的双阶段检索（Dual-stage Retrieval）架构：首阶段利用稠密向量搜索（Dense Retrieval）进行快速初筛，保障大规模私有库检索的广度与高召回率；次阶段引入 bge-reranker-v2-m3 模型作为 Cross-Encoder 进行深度重排序（Re-ranking）精排操作。重排序模型通过细粒度计算文档块与用户查询之间的深度相关性得分，有效滤除初筛阶段引入的无关噪声数据，确切保障最终输入给大模型的上下文证据具有极高的专业匹配度与准确率[1]。

3. **大模型控制层 (Model & Logic Layer)**：

本层是整个知识助手的“认知大脑”与逻辑编排控制中心。系统引入了高度模块化的 LangChain 框架进行工作流编排（Workflow Orchestration），实现数据层、处理层模型与外部接口的串联与状态调度。在核心的生成逻辑控制上，本层通过定制化提示工程（Prompt Engineering），设计了契合“成果导向教育（OBE）”理念的严格系统级提示词（Prompt）模板。该模板强制要求大模型将重排序后的高精度本地上下文证据与用户的 Query 进行有机组装，并严格限制其发散性思维，要求生成内容仅来源于检索结果。最终，系统通过对接调用 DeepSeek API 执行可控的文本生成任务。这种生成约束框架不仅赋予了通用大模型处理工程教育特定领域逻辑的能力，更从根本上抑制了其固有的“幻觉”现象，确保了专业问答事实严谨、无编造内容。

4. **应用与交互层 (Application Layer)**：

本层是系统直接面向终端用户（如认证专家、高校教务管理人员）的前端展示与操作门户。系统前端基于渐进式 JavaScript 框架 Vue 构建 Web 交互界面，注重布局的直观性与非技术人员的易用性。应用层重点封装了两大核心业务模块：一是“多轮自然语言问答”模块，支持用户在维护历史对话上下文的情境下，以自然、流畅的口语化方式对 EAC 繁杂指标和课程目标等问题进行深度追问与探索交互；二是“证据链可视化溯源”模块（本系统的核心工程亮点），该模块承接底层向量元数据与文件存储映射，在渲染 DeepSeek 生成的最终答案时，同步输出带标号的引文参考标注。用户仅需点击对应的引文标签，Web 界面即可实现文档分屏联动，直接跳转并精准定位（包含引文高亮与具体页码跳转）到原始 PDF 文档的对应段落。此举赋予了模型回答高度的“可解释性”与

“可溯源性”，完美契合工程认证业务中对材料严密互证与证据链闭环的极高监管要求。

4 核心模块设计与对比实验分析

4.1 复杂结构文档解析与精细化切块策略

工程教育专业认证（EAC）文档具有高度非线性的排版特征，包含复杂的培养目标达成度矩阵、跨页表格以及多级标题。传统 RAG 系统中基于纯文本流的解析与固定长度切块，会破坏表格的行列关系与上下文逻辑，导致检索阶段出现“语义坍塌”。因此，本节重点探讨高保真文档解析技术的选型及基于文档结构的切块策略。

4.1.1 解析引擎选型与 Benchmark 验证

为了客观评估并选择最适合本系统的文档解析方案，本文引入了权威的多模态文档解析端到端评测基准 OmniDocBench (v1.5) 作为参考。该基准包含真实 PDF 文档的复杂版面，其总体评分（Overall）由文本编辑距离（Text Edit distance）、表格还原度（Table TEDS）和公式准确率（Formula CDM）三项核心指标计算得出。

针对工程认证业务中占比极大的矩阵表格与公式指标，Table TEDS（Tree Edit Distance based Similarity）与 TEDS-S（纯表格结构还原度）是衡量解析器能力的决定性指标。表 4-1 截取了 2026 年第一季度 OmniDocBench 榜单中具有代表性的几类解析方案在全维度指标上的表现：

表 1: 代表性解析模型/工具在 OmniDocBench v1.5 的多维度端到端性能对比

模型/工具名称	技术类别	总体评分 (Overall ↑)	文本编辑距离 (TextEdit ↓)	公式准确率 (FormulaCDM ↑)	表格还原度 (TableTEDS ↑)	结构还原度 (TEDS-S ↑)	阅读顺序错误率 (ReadOrderEdit ↓)
PaddleOCR-VL	专用解析 VLM (0.9B)	92.86	0.035	91.22	90.89	94.76	0.043
MinerU2.5	专用解析 VLM (1.2B)	90.67	0.047	88.46	88.22	92.38	0.044
Gemini-2.5 Pro	通用 VLM	88.03	0.075	85.82	85.71	90.29	0.097
PP-StructureV3	Pipeline 工具	86.73	0.073	85.79	81.68	89.48	0.073
GPT-4o	通用 VLM	75.02	0.217	79.70	67.07	76.09	0.148
Marker-1.8.2	传统 Pipeline 工具	71.30	0.206	76.66	57.88	71.17	0.250

注：↑ 表示数值越高越好，↓ 表示数值越低越好。数据引用自[14]。

数据分析与选型依据：

通过表 1 的多维度数据对比可以发现，传统解析工具与通用大模型在“文本提取（TextEdit）”和“阅读顺序（ReadOrderEdit）”上表现尚可，但在处理复杂结构时暴露出明显瓶颈。例如，GPT-4o 虽然是通用的视觉语言模型，但其文本编辑距离高达 0.217，且表格还原度（TableTEDS）仅为 67.07。传统的开源 Pipeline 工具（如 Marker-1.8.2）在面对复杂排版时，阅读顺序错误率攀升至 0.250，且表格结构还原度（TEDS-S）仅为 71.17。这表明此类通用或传统工具无法胜任工程认证文档中跨页表格与嵌套公式的解析任务。

相反，参数量在 1.2B 及以下的专用解析模型（如 PaddleOCR-VL、MinerU2.5）不仅总体评分（Overall）突破了 90 分大关，其表格还原度（TableTEDS）和公式准确率（FormulaCDM）均保持在 88 以上。这证实了引入具备深度版面分析（Layout Analysis）能力的专用模型是解决结构化数据提取的必要途径。

基于上述详实的实证数据，本系统明确了摒弃基础 OCR 与简单文本提取框架的技术路线。系统最终采用 LlamaParse（或同级别具备高级视觉解析能力的引擎）作为核心解析组件，正是因为其底层技术逻辑与上述榜单头部的专用视觉解析模型一致，能够在保证"阅读顺序"不乱的前提下，高保真地重建 Markdown 表格结构，从而彻底消除 RAG 流程在数据摄入阶段的"语义坍塌"隐患。

4.1.2 语义感知与精细化切块策略

在获取高保真 Markdown 文本后，系统摒弃了传统的固定字符长度（Fixed-size Chunking）切分方式，转而采用了基于文档树结构的"语义感知切块（Semantic Structure-aware Chunking）"策略，具体实现如下：

1. **基于层级标签的物理切分**：解析器会识别 Markdown 中的标题标记（如 `#`、`##`）。系统将此类标记作为硬切分边界（Hard Boundary），确保属于同一章节的"课程目标"或"毕业要求"不会被机械性地从中间截断。
2. **元数据联级绑定（Metadata Injection）**：本系统的核心亮点在于证据链的可视化溯源。在切块过程中，系统提取当前区块的上下文属性，将对应的物理页码（Page Number）、所属章节树（Section Title）以及文件本地路径（Source Path）作为元数据（Metadata）与当前文本块强绑定。
3. **约束性回退机制**：仅当单一逻辑块的长度超过大模型上下文检索的最佳视窗（设定为 800 字符）时，系统才会触发次级的递归字符切分（Recursive Character Split），以确保向量库的检索粒度均衡。

该策略通过"结构还原 + 语义绑定"的双重保障，为后续的混合检索和高亮溯源奠定了坚实的数据基础。

4.2 领域知识向量化与 Embedding 模型选型

在检索增强生成（RAG）框架中，文本向量化（Embedding）的质量直接决定了第一阶段稠密检索（Dense Retrieval）的召回上限。针对工程教育专业认证（EAC）场景中存在的长文本解析与特定专业术语匹配需求，本节提出一个两阶段的模型选型方法：首先从主流榜单中筛选出若干候选模型，再通过本地测试集验证选出最优模型。

4.2.1 评测基准与选型约束条件

为客观评估不同文本向量模型在中文检索任务中的表现，本文选取 C-MTEB（Chinese Massive Text Embedding Benchmark）作为统一评测基准。该基准在检索（Retrieval）维度包含 T2Retrieval、MMarcoRetrieval、DuRetrieval 等多个子任务，并统一采用 nDCG@10 作为评价指标，通过对各子任务进行等权平均得到综合检索能力得分[15]。

结合本课题的业务实际，模型选型需严格满足以下工程约束：

1. **数据隐私与本地化部署**：高校工程认证材料（如试卷、达成度报告等）涉及内部教学数据，不可通过公网上传至第三方闭源 API（如 OpenAI Embedding），模型必须支持完全本地化私有部署。
2. **开源属性**：模型权重需完全开源，以便后续开展可能的领域数据微调（Fine-tuning）。
3. **参数规模可控**：考虑到常规服务器的显存限制，优先筛选参数量在 1B 以下，最高不超过 4B 的轻量级模型，以保障大规模文档索引构建的吞吐率。

4.2.2 榜单筛选与候选模型确定

基于上述约束，本文从公开的中文 Embedding 榜单中筛选了近年来具有代表性的开源模型，并汇总了其在 C-MTEB 检索任务上的公开评测数据（表 2）。通过综合考虑检索性能、参数规模及长文本支持能力，初步筛选出三个候选模型作为下一阶段验证对象：

- `bge-large-zh-v1.5`：在 C-MTEB 检索分数上表现优异，参数量适中。
- `bge-m3`：支持最长 8K tokens 的长文本建模，适合处理篇幅较长的认证文档。
- `MiniCPM-Embedding`：分数较高，但计算开销较大，作为性能上界参考。

表 2: 主流开源中文向量模型检索性能对比（用于榜单参考）

模型名称	参数规模	向量维度	Retrieval (nDCG@10)	架构特征/备注
text2vec-large-chinese	0.3B	1024	41.94	早期中文基线模型
m3e-large	未披露	1024	54.75	引入多任务训练增强
bge-base-zh	0.1B	768	63.13	轻量级、高性价比
bge-large-zh-v1.5	0.3B	1024	70.46	当前主流的高性能模型
bge-m3	0.57B	1024	65.43	支持多语言与长文本建模
Qwen3-Embedding-0.6B	0.6B	1024	71.03	新一代优化模型
piccolo-base-zh	未披露	768	71.20	工业级数据优化模型
MiniCPM-Embedding	2.4B	2304	76.76	性能较高但计算开销较大

注：表格数据来源于官方榜单[15]；↑ 表示数值越高越好，↓ 表示数值越低越好。

4.2.3 本地测试集验证与最终选型

在候选模型确定后，本文使用自行构建的 50 对工程教育认证（EAC）语义匹配测试样本进行本地验证，评估不同 embedding 模型在实际工程认证场景中的检索性能。评测指标主要包括 Hit@K 与 MRR，用于衡量模型的召回能力与排序质量。

候选模型包括 `bge-large-zh-v1.5`、`bge-m3` 以及 `MiniCPM-Embedding`。实验结果如表 3 所示。

表 3: 不同 Embedding 模型在 EAC 测试集上的检索性能对比

模型名称	MRR	Hit@1	Hit@5	Hit@10	Recall@5	Recall@10
bge-large-zh-v1.5	0.8412	0.80	0.88	0.92	0.88	0.92
bge-m3	0.8070	0.74	0.88	0.90	0.88	0.90
MiniCPM-Embedding	0.8017	0.70	0.92	0.92	0.92	0.92

从实验结果可以看出，不同模型在工程认证语料上的检索表现呈现出一定差异。具体而言，`bge-large-zh-v1.5` 在 MRR（0.8412）与 Hit@1（0.80）指标上表现最佳，说明其在排序能力与首条命中准确率方面具有一定优势；而 `MiniCPM-Embedding` 在 Hit@5 与 Hit@10 指标上达到最高（均为 0.92），表明其在候选召回覆盖率方面表现较强，但其在首条排序准确性（Hit@1 = 0.70）上相对较低。

相比之下，`bge-m3` 在各项指标上表现相对均衡（MRR = 0.807，Hit@5 = 0.88，Hit@10 = 0.90），在排序能力与召回能力之间取得了较好的折中。虽然其在单一指标上并未达到最优，但整体性能稳定，未出现明显短板。

结合定量实验结果与模型特性分析，本文最终选择 **`bge-m3`** 作为第一阶段稠密向量检索的基础模型。其主要理由如下：

- **综合性能均衡**：相较于其他模型在不同指标上的偏置表现，bge-m3 在召回与排序能力之间保持较好的平衡，更适合作为通用候选召回模型。
- **长文本建模能力**： bge-m3 支持更长上下文输入，能够较好适应工程认证文档中跨段落与复杂结构的语义匹配需求。
- **模型生态一致性**： bge-m3 与第二阶段精排模型 `bge-reranker-v2-m3` 属于同一模型体系，在表示空间上具有一致性，有助于提升双阶段检索流程的整体协同效果。
- **工程部署可行性**：在保证性能的同时，模型规模与计算开销适中，能够满足实际系统部署需求。

4.3 混合检索与重排序（Re-ranking）机制

4.3.1 单阶段稠密检索的局限性分析

在工程教育专业认证场景中，知识检索对象主要包括培养方案、课程教学大纲、毕业要求达成度分析报告及自评报告等多类型文档。此类文档通常具有篇幅较长、结构层级复杂、表格与正文交织以及同一语义关系跨段落分布等特点。因此，用户查询往往并非针对单一文本片段，而是需要在多个候选证据之间完成语义匹配与关系判别。在此背景下，若仅采用单阶段检索机制，难以同时兼顾召回范围与证据精度。

本文系统在初筛阶段采用基于 Bi-Encoder 架构的稠密向量检索方法，以 bge-m3 模型对用户查询与文档切块分别进行独立编码，并在统一向量空间中执行相似度匹配。这类方法与 Dense Passage Retrieval（DPR）所代表的 dense retrieval 范式一致，其优势在于能够对文档表示进行离线预计算，并结合向量数据库实现大规模近似最近邻检索，从而具备良好的效率与扩展性[16]。同时，Sentence-BERT 的研究表明，Bi-Encoder 通过预先计算文本向量，可以显著降低大规模语义匹配任务的在线计算复杂度[17]。

然而，Bi-Encoder 的高效率建立在“查询与文档独立表示”的机制之上，这也导致其在细粒度语义判别方面存在一定局限。首先，整体语义相似并不等同于能够构成有效证据支撑。在工程认证场景中，用户问题往往涉及“课程—毕业要求支撑关系”等明确逻辑约束，仅依赖向量相似度难以判断文本是否真正回答问题。

其次，文档切块过程可能带来上下文割裂。尽管本文采用语义感知切块策略以尽量保持语义完整性，但在长文档与复杂结构场景中，关键证据仍可能分布于不同文本块甚至跨页位置，从而影响单块检索的有效性。

再次，为保证召回覆盖率，初筛阶段通常设置较大的 Top-K 值，这在提升召回率的同时，也会引入更多“语义相关但不直接回答问题”的噪声片段。相关研究表明，在排序任务中，Cross-Encoder 相较于 Bi-Encoder 具有更强的判别能力[18]。同时，将 BERT 作为 Cross-Encoder 引入重排序阶段，可以显著提升候选文档的排序质量[19]。

综上所述，单阶段稠密检索适合作为候选召回模块，但难以满足工程认证场景对证据精度与语义判别能力的要求。因此，有必要在初筛结果基础上引入精排机制，以实现从“高召回”到“高精度”的检索优化。

4.3.2 双阶段检索框架设计

针对上述问题，本文设计了“初筛—精排”的双阶段检索机制。该机制通过将稠密向量检索与 Cross-Encoder 重排序相结合，在保证检索效率的同时提升候选结果的相关性与准确性。这种“retrieve + rerank”的两阶段检索范式已在问答系统与检索增强生成任务中得到广泛应用[20-21]。

双阶段检索流程可形式化表示为：

$$Q \xrightarrow{\text{Embedding}} \mathbf{q} \xrightarrow{\text{Dense Retrieval}} \{d_1, d_2, \ldots, d_K\} \xrightarrow{\text{Re-ranking}} \{d_{(1)}, d_{(2)}, \ldots, d_{(N)}\} \quad (2)$$

其中，Q 表示用户查询，$\mathbf{q}$ 表示查询向量，$\{d_1, d_2, \ldots, d_K\}$ 表示初筛阶段返回的候选文本集合，$\{d_{(1)}, d_{(2)}, \ldots, d_{(N)}\}$ 表示经重排序后选取的高相关文本集合。

在初筛阶段，系统采用 bge-m3 模型对查询与文档进行向量化表示，并基于向量数据库执行相似度检索。根据 M3-Embedding 的研究，bge-m3 模型具备多语言、多粒度与多功能统一建模能力，能够支持较长文本输入，并在检索任务中表现出较强的语义表达能力[22]。因此，该模型适合作为工程认证场景中的第一阶段召回模型，其核心目标在于最大程度保留潜在相关证据。

在精排阶段，系统引入 bge-reranker-v2-m3 对候选集合进行逐对重排序。该模型基于 Cross-Encoder 架构，将查询与文本拼接后输入统一编码器，从而在 token 级别建模两者之间的交互关系。与 Bi-Encoder 相比，该机制能够更准确判断文本是否真正回应用户问题，从而有效过滤初筛阶段引入的噪声片段[17-18]。在开放域问答研究中，加入 reranker 能够显著提升最终排序质量与问答性能[19,23]。

从系统功能角度看，双阶段检索机制具有以下优势：首先，初筛阶段能够在大规模知识库中快速缩小候选范围；其次，精排阶段能够进一步提升候选集合的相关性与纯净度；最后，经重排序后的文本更适合作为生成模块的输入，有助于减少无关信息干扰，提高回答结果与证据之间的一致性。

需要说明的是，本文检索机制完全基于稠密语义匹配与 Cross-Encoder 重排序构建，并未引入 BM25 等稀疏检索方法。这一设计是基于工程认证文档中存在大量同义表达与隐式语义关系的特点，单纯依赖关键词匹配难以有效捕获复杂语义关联。

综上，双阶段检索机制通过“高召回 + 高精度”的分阶段处理策略，实现了检索效率与证据质量之间的平衡，为后续基于检索增强生成的答案生成与证据链溯源提供了可靠基础。

4.4 提示工程设计与生成约束

在完成检索阶段后，系统将候选文本块作为上下文输入大模型进行答案生成。然而，大语言模型在生成过程中仍可能出现“幻觉（Hallucination）”现象，即生成内容与真实知识不一致或缺乏证据支撑。已有研究表明，即使在引入检索增强生成（RAG）框架后，模型仍可能产生与检索内容不一致的回答，因此需要进一步引入约束机制以保证生成结果的可靠性。

为此，本文在生成阶段设计了严格的提示工程（Prompt Engineering）策略，通过系统级约束引导模型仅基于检索结果进行回答，从而降低幻觉风险并增强证据链可追溯性。

4.4.1 基于检索约束的生成机制

RAG 框架的核心思想是在生成阶段引入外部知识，使模型不再依赖参数化记忆，而是基于检索到的上下文进行回答。相关研究表明，引入可靠外部信息能够显著降低模型的幻觉率，并提升回答的事实一致性。

在本文系统中，生成模型的输入由以下三部分构成：

$$\text{Input} = \{\text{System Prompt}, \text{Query}, \text{Retrieved Context}\} \tag{3}$$

其中，Retrieved Context 由双阶段检索模块输出的 Top-N 文本块组成，并附带对应的元数据（如文件路径与页码）。模型被明确约束只能基于该上下文进行回答。

4.4.2 系统级 Prompt 约束设计

为避免模型脱离检索内容进行自由生成，本文设计了如下系统级提示模板：

> 你是一个工程教育认证知识助手。请严格依据提供的参考材料回答问题。要求：（1）只能基于给定材料回答，不得使用外部知识；（2）若材料中未包含答案，请明确说明“未在材料中找到相关信息”；（3）回答中必须标注引用来源（页码或文档片段）。

该设计属于典型的“约束式提示（Constraint-based Prompting）”方法。研究表明，明确的指令约束与上下文限定可以显著降低模型生成不准确信息的概率。同时，通过限制模型输出来源，可以有效避免其基于概率分布进行“补全式猜测”。

4.4.3 证据驱动的引用生成机制

为了进一步增强回答的可解释性，本文在 Prompt 中引入“证据引用”要求，即模型在生成答案时必须标注对应的来源文本。具体实现方式为：

- 在输入上下文中为每个文本块附加编号或元数据标识；
- 在 Prompt 中显式要求模型输出引用标记；
- 在前端系统中根据引用信息实现文档定位与高亮展示。

已有研究表明，在 RAG 系统中引入显式引用机制可以显著提升答案的可验证性，并帮助用户判断信息来源的可靠性。同时，这种“证据绑定生成”方式能够抑制模型生成无依据内容，从而降低幻觉风险。

4.4.4 幻觉抑制机制分析

综合来看，本文的生成约束策略主要从以下三个方面抑制幻觉：

- **知识来源约束**：通过限制模型仅使用检索内容进行生成，避免依赖参数化记忆；
- **指令约束**：通过系统 Prompt 明确规定回答范围与行为规则，减少不确定性；
- **证据绑定**：通过强制引用来源，使模型输出与具体文本片段建立对应关系。

相关研究指出，提示工程在幻觉控制中具有重要作用，合理设计 Prompt 可以显著降低错误生成概率。此外，RAG 框架通过引入外部知识源，本身也是当前缓解幻觉问题的重要技术路径之一。

4.4.5 与系统证据链机制的协同作用

在本文系统中，生成模块并非孤立存在，而是与前端“证据链可视化”模块形成闭环。具体而言，生成结果中的引用信息将直接映射至原始文档的具体位置，实现以下功能：

- 支持页码级跳转与原文高亮；
- 提供可追溯的证据链路径；
- 提升系统输出的可信度与可验证性。

因此，提示工程不仅用于控制生成行为，还在系统层面与检索模块及前端展示模块协同作用，共同构建“检索—生成—溯源”的闭环机制。

综上，本文通过引入基于检索约束的提示工程策略，实现了对大模型生成行为的有效控制，在降低幻觉风险的同时，提升了答案的可解释性与证据链完整性。

5 系统实现与整体性能评测

5.1 开发环境与系统部署

本文所提出的工程教育认证私有知识助手系统基于 RAG（Retrieval-Augmented Generation）框架实现，整体采用前后端分离架构。系统在开发与部署过程中所使用的关键软硬件环境如下：

- **开发语言与框架**：后端采用 Python 语言开发，结合 LangChain 实现检索与生成流程编排；前端基于 Vue 框架构建交互界面；

- **向量数据库**：采用 Chroma 作为向量存储引擎，用于存储文本块及其对应的稠密向量表示；
- **嵌入与重排序模型**：第一阶段采用 `bge-m3` 进行向量化表示，第二阶段采用 `bge-reranker-v2-m3` 进行候选重排序；
- **大模型接口**：系统调用 Kimi API 作为生成模型，通过提示工程实现约束式生成；
- **运行环境**：系统部署于本地服务器环境，支持 GPU 加速（如 NVIDIA RTX 系列），操作系统为 Windows / macOS。

在系统部署流程上，首先完成工程认证相关文档的批量导入，包括培养方案、课程大纲及达成度分析报告等。随后执行文档解析与语义切块操作，将文本块及其元数据（文件路径、页码信息）写入向量数据库。在完成知识库构建后，系统即可对外提供检索与问答服务。

整体部署流程如式（5-1）所示：

$$\text{Document} \rightarrow \text{Parsing} \rightarrow \text{Chunking} \rightarrow \text{Embedding} \rightarrow \text{Vector DB} \tag{4}$$

通过上述部署方式，系统实现了从原始多模态文档到结构化知识库的转换，为后续检索与生成模块提供基础支撑。

5.2 核心功能模块实现与界面展示

本文系统围绕工程认证知识查询需求，设计并实现了多模块协同的功能体系，主要包括文档处理模块、检索模块、生成模块及前端展示模块。

（1）文档处理模块 系统在数据预处理阶段采用语义感知切块（Semantic Chunking）方法，将长文档划分为语义相对完整的文本块。同时，为每个文本块绑定对应的元数据（包括文件路径与页码），以支持后续的证据定位与溯源。

（2）双阶段检索模块 检索模块严格按照“初筛—精排”流程实现。首先利用 `bge-m3` 模型对查询与文本块进行向量化，并在向量数据库中执行 Top-K 检索；随后利用 `bge-reranker-v2-m3` 对候选结果进行逐对评分，筛选出高相关文本作为最终上下文。

（3）生成模块 生成模块基于 Kimi 大模型接口实现。在输入端，系统将查询与检索上下文拼接，并结合预定义 Prompt 模板对模型进行约束，要求其仅基于检索内容生成回答，并输出对应引用信息，从而降低幻觉风险。

（4）前端展示模块　前端采用 Vue 框架开发，实现了查询输入、结果展示及证据链可视化功能。系统支持将生成答案中的引用信息映射至原始文档，实现页码级跳转与高亮展示。

系统界面示意如图 2 所示。

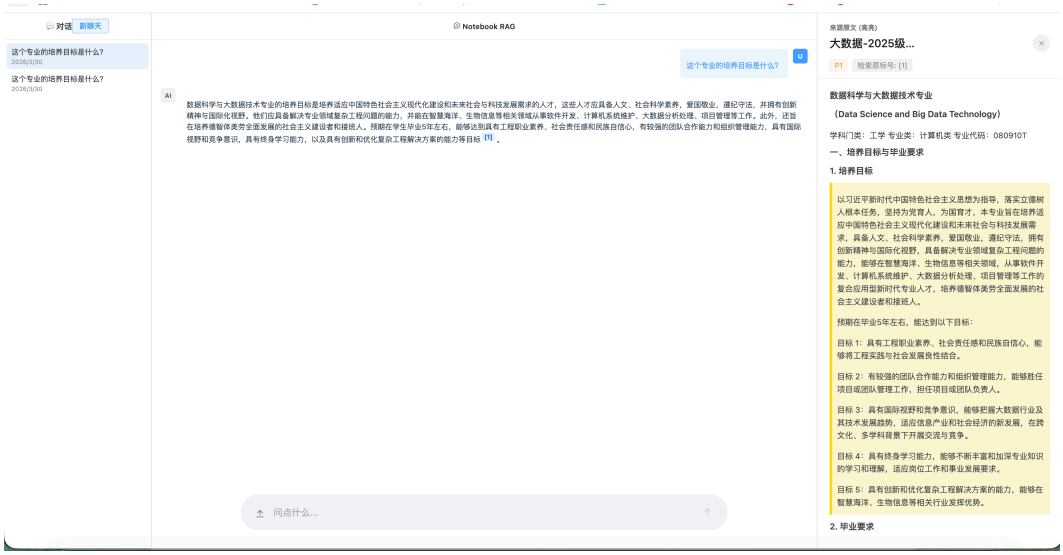

图 2: 系统问答界面与证据链展示示意图

通过上述模块协同，系统实现了从用户查询到证据可视化展示的完整闭环流程。

5.3　端到端系统整体性能评估

基于前述实验设计，本文对三种系统配置（Dense-RAG、Dense+Rerank-RAG、Dense+Rerank+ConstrainedPrompt）进行了端到端性能评估。实验结果分别从检索性能与生成质量两个方面进行分析。

（1）检索性能分析　检索性能评估结果如表 4 所示。

表 4: 不同系统配置下的检索性能对比

系统	Hit@5	Hit@10	MRR
Dense-RAG	0.8980	0.9184	0.8324
Dense+Rerank	0.9184	0.9184	0.8782
Dense+Rerank+Prompt	0.9184	0.9184	0.8782

从检索结果可以看出，引入重排序机制后，系统在 MRR 指标上由 0.8324 提升至 0.8782，说明 Cross-Encoder 能够有效优化候选文本的排序质量，使正确答案在候选列表中的排名更加靠前。同时，Hit@5 指标由 0.8980 提升至 0.9184，表明重排序在一定程度上提升了检索覆盖率。

需要注意的是，S2 与 S3 在检索指标上保持一致，这是因为提示工程约束仅作用于生成阶段，不影响检索过程。

（2）生成质量分析 生成质量评估结果如表 5 所示。

表 5: 不同系统配置下的生成质量与证据链效果对比

系统	Faithfulness	Answer Relevance	Citation Accuracy	Traceability
Dense-RAG	0.9606	0.8808	0.0200	0.0400
Dense+Rerank	0.9092	0.8925	0.6657	0.8200
Dense+Rerank+Prompt	0.9020	0.8783	0.7657	0.9000

从生成指标来看，不同系统在多个维度上表现出明显差异。

首先，在 Faithfulness 指标上，Dense-RAG 表现最高（0.9606），而引入重排序后略有下降（约 0.91）。这一现象说明，单纯依赖稠密检索时，模型可能更倾向于生成语义一致但较为宽泛的回答，从而在自动评测中获得较高分数。然而，这种“高一致性”并不一定对应真实的证据支撑。

其次，在 Answer Relevance 指标上，Dense+Rerank 系统达到最高（0.8925），说明精排后的上下文更有助于生成与问题更加匹配的回答。

最显著的提升体现在证据链相关指标上。Citation Accuracy 从 Dense-RAG 的 0.02 大幅提升至 0.6657，并在加入 Prompt 约束后进一步提升至 0.7657；Traceability Success Rate 由 0.04 提升至 0.82，并最终达到 0.90。这表明，引入重排序机制能够显著提升候选文本的有效性，而提示工程约束则进一步强化了生成结果与原始文档之间的绑定关系。

（3）综合分析 综合实验结果可以得到以下结论：

（1）重排序机制显著提升了检索排序质量（MRR 提升约 5.5%），并间接提升生成答案的相关性；

（2）提示工程约束对生成内容的“证据绑定能力”具有决定性作用，是提升系统可解释性的关键因素；

（3）Dense-RAG 虽在 Faithfulness 指标上表现较高，但在证据链指标上表现较差，说明其生成结果缺乏可靠来源支撑；

（4）双阶段检索与生成约束的结合，使系统在“回答准确性”与“证据可追溯性”之间取得了更合理的平衡。

因此，在工程教育认证场景中，S3（完整系统）能够更好地满足实际应用对可靠性与可解释性的要求。

6 总结与展望

6.1 全文工作总结

本文围绕工程教育专业认证（EAC）与成果导向教育（OBE）背景下复杂文档知识管理与查询困难的问题，设计并实现了一个基于检索增强生成（RAG）框架的工程认证私有知识助手系统。

针对工程认证文档类型多样、结构复杂、证据链分散等特点，本文从文档解析、语义检索与生成约束三个层面展开研究，构建了完整的系统技术方案。主要工作总结如下：

（1）在数据处理层，针对工程认证文档结构复杂的问题，提出基于语义感知切块（Semantic Chunking）的文档处理方法，并为每个文本块绑定文件路径与页码等元数据，实现从原始文档到可检索知识单元的结构化转化。

（2）在检索机制方面，设计了“初筛—精排”的双阶段检索框架。首先基于 `bge-m3` 模型进行稠密向量检索，以保证候选文本的覆盖率；随后引入 `bge-reranker-v2-m3` 进行重排序，从而提升候选结果的相关性与排序质量。

（3）在生成阶段，针对大语言模型可能产生幻觉的问题，设计了基于提示工程的生成约束机制，通过限制模型仅基于检索内容回答并输出引用来源，有效提升生成结果的可靠性与可解释性。

（4）在系统实现层面，基于 Vue、LangChain 与向量数据库构建了完整的工程系统，并实现了证据链可视化功能，使用户能够从生成答案直接跳转至原始文档对应位置，从而验证信息来源。

（5）在实验评估方面，本文通过端到端实验验证了系统的有效性。实验结果表明，引入重排序机制能够提升检索排序质量，而提示工程约束显著增强了生成结果的证据一致性与可追溯性，从而使系统在工程认证场景中具备良好的应用价值。

综上，本文提出的工程认证私有知识助手系统在检索效率、生成质量与证据链可解释性之间取得了较好的平衡，为复杂工程文档的智能化管理与应用提供了一种可行方案。

6.2 系统局限性与未来展望

尽管本文所提出的系统在工程认证知识问答任务中取得了一定效果，但仍存在一些局限性，有待进一步改进。

（1）**文档解析能力仍存在提升空间。**当前系统主要基于通用解析工具进行文档结构提取，在处理复杂排版（如跨页表格、嵌套结构与扫描文档）时仍可能存在信息缺

失或结构误识别的问题。未来可结合更先进的多模态文档解析模型，以提升复杂文档的结构化能力。

（2）**检索模型对领域语义的适应性有限**。虽然本文采用的 `bge-m3` 模型在通用语义检索任务中表现良好，但其未针对工程认证领域进行专门训练，在处理专业术语与隐式语义关系时仍存在一定局限。未来可通过领域数据微调或构建领域专用嵌入模型，进一步提升检索效果。

（3）**生成评测仍依赖有限指标**。本文主要采用 Faithfulness 与 Answer Relevance 等指标对生成结果进行评估，但这些指标仍难以全面反映复杂问答任务中的语义质量。未来可结合更细粒度的评测方法，如多维人工评估或领域专家评审，以获得更全面的性能评价。

（4）**证据链构建仍依赖文本粒度**。当前系统的证据链以文本块为基本单位，在处理跨块推理或多证据融合问题时存在一定局限。未来可探索基于图结构的知识表示方法，将文档内容组织为知识图谱，以支持更复杂的推理能力。

（5）**系统扩展性与实时性能有待优化**。随着知识库规模的不断扩大，系统在检索效率与响应时间方面可能面临挑战。未来可结合向量索引优化技术或分布式检索架构，以提升系统在大规模数据场景下的性能表现。

未来工作可从以下方向展开：

（1）引入多模态文档理解能力，实现对图表、公式及扫描文档的统一解析；（2）结合领域知识构建更精细的知识表示结构，提升复杂语义推理能力；（3）优化提示工程与生成策略，进一步降低幻觉风险；（4）提升系统在真实教学管理场景中的部署与应用能力。

综上，本文工作为工程认证文档智能化处理提供了初步探索，未来仍有较大提升空间，有望在更广泛的教育与知识管理场景中发挥作用。

参考文献

[1] GAO Y, XIONG Y, GAO X, et al. Retrieval-Augmented Generation for Large Language Models: A Survey[M/OL]. arXiv, 2024[2025-11-04]. http://arxiv.org/abs/2312.10997. DOI: 10.48550/arXiv.2312.10997.

[2] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[M/OL]. arXiv, 2021[2025-11-10]. http://arxiv.org/abs/2005.11401. DOI: 10.48550/arXiv.2005.11401.

[3] 李志义. 解析工程教育专业认证的成果导向理念[J/OL]. 中国高等教育, 2014(17): 7-10[2025-11-10]. https://kns.cnki.net/KCMS/detail/detail.aspx?dbcode=CJFQ&dbname=CJFD2014&filename=ZGDJ201417005.

[4] 林健. 工程教育认证与工程教育改革和发展[J/OL]. 高等工程教育研究, 2015 (2): 10-19[2025-11-10]. https://kns.cnki.net/KCMS/detail/detail.aspx?dbcode=CJFQ&dbname=CJFDLAST2015&filename=GDGJ201502003.

[5] TAIPALUS T. Vector database management systems: Fundamental concepts, use-cases, and current challenges[J/OL]. Cognitive Systems Research, 2024, 85: 101216[2025-11-10]. http://arxiv.org/abs/2309.11322. DOI: 10.1016/j.cogsys.2024.101216.

[6] MA L, ZHANG R, HAN Y, et al. A Comprehensive Survey on Vector Database: Storage and Retrieval Technique, Challenge[M/OL]. arXiv, 2025[2025-11-10]. http://arxiv.org/abs/2310.11703. DOI: 10.48550/arXiv.2310.11703.

[7] 孙雨生, 曾俊皓. 向量数据库及其应用研究[J/OL]. 科技情报研究, 2024, 6(4): 11-24[2025-11-10]. https://doi.org/10.19809/j.cnki.kjqbyj.2024.04.002.

[8] JÉGOU H, DOUZE M, SCHMID C. Product Quantization for Nearest Neighbor Search[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2011, 33(1): 117-128[2025-11-10]. https://ieeexplore.ieee.org/document/5432202. DOI: 10.1109/TPAMI.2010.57.

[9] LUO K, LIU Z, ZHANG P, et al. Does RAG Really Perform Bad For Long-Context Processing?[M/OL]. arXiv, 2025[2025-11-10]. http://arxiv.org/abs/2502.11444. DOI: 10.48550/arXiv.2502.11444.

[10] 张丽静, 杜冬梅, 刘庆芳, 等. 基于 LLM 和 RAG 的中邮网院智能客服系统研究[J/OL]. 邮政研究, 2024, 40(4): 66-72[2025-11-10]. https://doi.org/10.13955/j.yzyj.2024.04.11.07.

[11] 冯腾发, 蒋耀宇, 陈浩杰, 等. RAG 知识库在低资源领域知识问答中的应用[J/OL]. 通讯世界, 2025, 32(9): 21-23[2025-11-10]. https://kns.cnki.net/KCMS/detail/detail.aspx?dbcode=CJFQ&dbname=CJFDLAST2025&filename=TXSJ202509007.

[12] 孙如玉, 齐正, 张云贵, 等. HSR-RAG: 面向钢铁材料国家标准的层级语义递归 RAG[J/OL]. 冶金自动化, 2025, 49(5): 87-96[2025-11-10]. https://kns.cnki.net/KCMS/detail/detail.aspx?dbcode=CJFQ&dbname=CJFDAUTO&filename=YJZH202505009.

[13] ZHAO Y, LIN M, TANG H, et al. Merino: Entropy-driven Design for Generative Language Models on IoT Devices[M/OL]. arXiv, 2025[2025-11-10]. http://arxiv.org/abs/2403.07921. DOI: 10.48550/arXiv.2403.07921.

[14] OUYANG L, QU Y, ZHOU H, et al. OmniDocBench: benchmarking diverse PDF document parsing with comprehensive annotations[A/OL]. arXiv (2024). https://arxiv.org/abs/2412.07626.

[15] C-MTEB: chinese massive text embedding benchmark[EB/OL]. https://github.com/FlagOpen/FlagEmbedding/tree/master/C_MTEB.

[16] KARPUKHIN V, OGUZ B, MIN S, et al. Dense passage retrieval for open-domain question answering[C/OL]//WEBBER B, COHN T, HE Y, et al. Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). Online: Association for Computational Linguistics, 2020: 6769-6781. https://aclanthology.org/2020.emnlp-main.550/. DOI: 10.18653/v1/2020.emnlp-main.550.

[17] REIMERS N, GUREVYCH I. Sentence-BERT: sentence embeddings using Siamese BERT-networks[C/OL]//INUI K, JIANG J, NG V, et al. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). Hong Kong, China: Association for Computational Linguistics, 2019: 3982-3992. https://aclanthology.org/D19-1410/. DOI: 10.18653/v1/D19-1410.

[18] HUMEAU S, SHUSTER K, LACHAUX M A, et al. Poly-encoders: architectures and pre-training strategies for fast and accurate multi-sentence scoring[C/OL]//International Conference on Learning Representations. 2020. https://openreview.net/forum?id=SkxgnnNFvH.

[19] NOGUEIRA R, CHO K. Passage re-ranking with BERT[A/OL]. arXiv (2020). https://arxiv.org/abs/1901.04085.

[20] GLASS M, ROSSIELLO G, CHOWDHURY M F M, et al. Re2G: retrieve, rerank, generate[C/OL]//CARPUAT M, DE MARNEFFE M C, MEZA RUIZ I V. Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Seattle, United States: Association for Computational Linguistics, 2022: 2701-2715. https://aclanthology.org/2022.naacl-main.194/. DOI: 10.18653/v1/2022.naacl-main.194.

[21] YU D, ZHU C, FANG Y, et al. KG-FiD: infusing knowledge graph in fusion-in-decoder for open-domain question answering[C/OL]//MURESAN S, NAKOV P, VILLAVICENCIO A. Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Dublin,

Ireland: Association for Computational Linguistics, 2022: 4961-4974. https://aclanthology.org/2022.acl-long.340/. DOI: 10.18653/v1/2022.acl-long.340.

[22] CHEN J, XIAO S, ZHANG P, et al. M3-embedding: multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation[C/OL]//KU L W, MARTINS A, SRIKUMAR V. Findings of the Association for Computational Linguistics: ACL 2024. Bangkok, Thailand: Association for Computational Linguistics, 2024: 2318-2335. https://aclanthology.org/2024.findings-acl.137/. DOI: 10.18653/v1/2024.findings-acl.137.

[23] IYER S, MIN S, MEHDAD Y, et al. RECONSIDER: improved re-ranking using span-focused cross-attention for open domain question answering[C/OL]//TOUTANOVA K, RUMSHISKY A, ZETTLEMOYER L, et al. Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Online: Association for Computational Linguistics, 2021: 1280-1287. https://aclanthology.org/2021.naacl-main.100/. DOI: 10.18653/v1/2021.naacl-main.100.