摘要

随着大规模语言模型（LLM）的快速发展，其在知识密集型任务中的应用潜力获得了广泛认可。然而，LLM 在处理高校工程教育专业认证（EAC）等私有领域文档时，面临知识滞后、易产生“幻觉”且缺乏可溯源性等挑战。针对上述问题，本文设计并实现了一个基于检索增强生成（RAG）框架的智能知识助手系统.....

关键词：检索增强生成；大语言模型；工程教育认证；向量数据库；信息抽取

目 录

1 绪论 4
1.1 研究背景 4
1.2 研究意义 4
1.3 国内外研究现状 5
1.3.1 国外研究现状 5
1.3.2 国内研究现状 5
1.4 研究主要内容与预期目标 6
1.4.1 研究主要内容 6
1.4.2 预期目标 7

2 相关理论与核心技术基础 7
2.1 大规模语言模型与提示工程 7
2.1.1 大语言模型 (LLM) 理论基础 7
2.1.2 提示工程 8
2.1.3 基于上下文的约束提示与幻觉抑制 8
2.2 检索增强生成（RAG）技术原理 8
2.2.1 RAG 的基本定义与核心价值 8
2.2.2 RAG 的标准执行范式 9
2.2.3 技术演进：从 Naive RAG 到 Advanced RAG 9
2.3 向量数据库与检索技术 10
2.3.1 文本向量化表示（Embedding）原理 10
2.3.2 相似度计算机制 10
2.3.3 向量数据库与 ANN 算法 10
2.4 工程教育专业认证与 OBE 理念 11
2.4.1 工程教育专业认证的背景与目的 11
2.4.2 成果导向教育（OBE）的核心内涵 11
2.4.3 业务痛点关联：证据链管理与溯源挑战 11

3 知识助手系统需求分析与总体设计 12
3.1 系统需求分析 12
3.1.1 功能性需求分析 12
3.1.2 功能性需求分析 13
3.2 系统总体架构设计 14
3.3 核心业务流程设计 15

4 核心模块设计与对比实验分析 15

4.1 复杂结构文档解析与精细化切块策略 15
4.2 领域知识向量化与 Embedding 模型选型 15
4.3 混合检索与重排序（Re-ranking）机制 16
4.4 提示工程设计与生成约束 16

5 系统实现与整体性能评测 16
5.1 开发环境与系统部署 16
5.2 核心功能模块实现与界面展示 16
5.3 端到端系统整体性能评估 16

6 总结与展望 16
6.1 全文工作总结 16
6.2 系统局限性与未来展望 16

1 绪论

1.1 研究背景

大规模语言模型（LLM）自 Transformer 架构问世以来，凭借其在自然语言理解、上下文推理和文本生成等方面的卓越表现，已成为人工智能领域最具革命性的技术之一。LLM 在通用知识问答、摘要生成和代码辅助等知识密集型任务中的应用潜力获得了广泛认可。

然而，由于 LLM 的知识本质上是隐式存储于其数千亿级的参数之中，这种参数化记忆模式存在固有的挑战：首先，模型的知识库是静态且有时效性限制的，难以应对日新月异的实时信息；其次，LLM 在处理复杂或低频知识时，极易出现“幻觉”（Hallucination）现象，即生成看似合理但事实上错误或虚构的内容[1]；更关键的是，其推理过程是一个“黑箱”，缺乏透明性和可溯源性，这对于需要严格证据链支撑的垂直应用场景是不可接受的[2]。

为了克服这些局限性，检索增强生成（Retrieval-Augmented Generation, RAG）框架应运而生。RAG 代表了一种范式创新，它将 LLM 的内在（参数化）知识与庞大、动态的外部（非参数化）知识库进行协同融合。其核心机制是在 LLM 生成答案之前，通过智能检索器从外部数据库中提取最相关的证据或文档片段，并将这些证据作为上下文输入给 LLM 进行条件生成。RAG 框架通过这种“先检索，后生成”的方式，有效地解决了知识时效性、幻觉和透明度问题，从而保证了模型回答的高准确性、知识的实时性和证据链的可溯源性。这使得 RAG 成为将 LLM 安全、精准地引入到对可信赖性有极高要求的垂直领域的关键技术。

1.2 研究意义

本研究的特定背景为高校工程教育专业认证（EAC）工作，其核心理念是成果导向教育（OBE）[3-4]。该工作具有知识密度高、文档类型复杂（如课程大纲、试卷、学生报告、自评报告等海量私有文档）、以及对证据链完整性和溯源精准度有极高监管要求的特点。传统的认证工作流程高度依赖人工查阅，不仅耗费大量时间精力，且极易导致证据链遗漏或断裂，严重影响认证效率和质量。

基于此，设计并实现一个基于检索增强生成（RAG）框架的智能知识助手系统，以提供一个安全、精准、可追溯的工程认证知识服务平台，具有重要的现实意义：

- **提升认证工作效率：**通过提供标准查询、证据链溯源等功能，能够帮助认证人员快速定位关联证据，显著缩短查阅时间，提升效率和准确度。
- **保障认证质量与促进持续改进：**系统能够确保证据链的完整且准确[4]，降低人为失误风险，同时支持对知识关联性的深度挖掘，辅助专业建设持续改进。

- **私有知识的安全与便捷管理：**利用向量数据库和 RAG 框架，可实现对海量分散私有文档的统一管理和高效检索，将文档转化为可被高效访问的知识资产。

1.3 国内外研究现状

1.3.1 国外研究现状

国外研究在大型语言模型的知识增强、向量数据库构建以及 RAG 性能优化方面处于理论和技术的前沿，为本领域提供了坚实的底层基础。

检索增强生成（RAG）框架的提出是解决 LLM 知识局限性的关键突破。Lewis 等（2020）[2] 开创性地提出了 RAG 模型，将预训练的 Seq2Seq 模型与可微分的外部非参数记忆相结合，证明了该模型能够显著提升 LLM 在知识密集型任务上的性能，同时解决了 LLM 决策不可溯源的问题，为模型的生成结果提供了证据来源（provenance）（见[2] Abstract）。在此基础上，Gao 等（2024）[1] 系统地将 RAG 的发展划分为 Naive RAG、Advanced RAG 和 Modular RAG 三个阶段（见[1] Abstract），并强调 Advanced RAG 范式致力于对“检索、增强、生成”这三个核心环节进行全面、精细化的优化，是当前研究的主流方向。

支撑 RAG 框架核心检索功能的是向量数据库（VDB）。Taipalus（2024）[5] 和 Ma 等（2025）[6] 的研究均指出，VDB 的出现是为了管理传统数据库难以处理的高维向量数据，并已成为现代 AI 系统中的关键组件，广泛应用于相似性搜索和智能问答系统（见[5] Abstract,[6] Abstract）。孙雨生和曾俊皓（2024）[7] 进一步细化了 VDB 的关键技术，包括向量数据的嵌入生成、索引和检索（见[7] 结果/结论）。为了实现 VDB 的高性能检索，高效的近似最近邻（ANN）搜索算法至关重要。其中，Jégou 等（2011）[8] 提出的乘积量化（Product Quantization, PQ）算法，通过将高维空间分解并进行量化，是实现大规模向量索引和检索，同时兼顾速度和内存效率的核心技术之一（见[8] Abstract）。此外，针对工程认证文档这类复杂、长篇的文本，RAG 面临检索不准确和上下文碎片化的挑战，Luo 等（2025）[9] 提出了 RetroLM 框架，创新性地引入了 KV-level 检索增强机制（见[9] Abstract），通过在 LLM 的键值缓存（KV Cache）层面进行检索，显著提高了模型对检索结果的有效利用率，为本课题处理复杂的长文档关联性问题提供了技术参考。

1.3.2 国内研究现状

国内研究主要聚焦于 RAG 技术的实践应用和工程教育领域的核心理论探讨，为本课题的应用场景和优化方向提供了实践经验和理论基础。

在 RAG 应用实践方面，国内研究已将 RAG 技术成功应用于企业客服和垂直知识问答系统。例如，张丽静等（2024）[10] 在智能客服系统中的研究，验证了基于 LLM 和 RAG 实现智能客服的可行性，并强调系统在实际应用中必须具备可溯源性和安全

性（见[10] 摘要）。同时，冯腾发（2025）[11] 对 RAG 知识库在低资源领域的应用进行了深入研究，实践证明 RAG 系统的性能高度依赖于文档切块策略和检索增强技术的选择，这为本课题的系统调优提供了经验指导（见[11] 引言/正文）。

本课题的应用领域对知识的权威性、精准性和证据链的完整性要求极高。在工程教育领域的核心理念方面，李志义（2014）[3] 详细解析了工程教育专业认证的核心——成果导向教育（OBE）理念，强调教育目标应以“学生毕业时应达到的能力和成果”为导向（见[3] 第一段）。而林健（2015）[4] 则进一步指出，认证工作的关键挑战在于对证据链条的高效管理和准确溯源，即如何可靠地证明课程目标与毕业要求之间的关联是完整且有效的（见[4] 英文摘要）。针对工程认证文档条款间语义耦合性强、证据链条复杂的特点，孙如玉等（2025）[12] 提出了 HSR-RAG（层级语义递归 RAG），该方法通过建立基于文档结构特征的多级语义解析模型和递归式语义聚合算法，有效解决了标准文本处理中存在的知识碎片化与语义关联弱化等局限性（见[12] 摘要），为本课题设计 OBE 导向的结构化切块策略提供了关键的技术思路。

1.4 研究主要内容与预期目标

1.4.1 研究主要内容

(1) 基于结构化感知的复杂文档解析与知识库构建。针对工程认证中涉及的海量多模态非结构化文档（如培养方案、自评报告、教学大纲等），本文将重点探讨基于文档逻辑结构的语义切块（Chunking）策略，以克服传统固定字符切分导致的语义破损问题。同时，通过设计对比实验，定量分析不同解析工具在处理复杂表格、跨页段落及多级标题时的提取准确度，最终构建一个支持结构化感知的高质量本地私有知识库。

(2) 面向工程认证领域的向量化检索与重排序机制设计。为满足工程教育特定术语（如“毕业要求指标点”、“OBE”等）的精准语义匹配需求，本文将引入适合该垂直领域的 Embedding 模型，并构建专属测试集（Golden Dataset）对主流中英文 Embedding 模型进行交叉评估。在检索策略设计上，本文采用“初筛-精排”的双阶段架构：首先通过稠密向量（Dense Vector）检索召回初步相关的文档块；随后，引入基于 bge-reranker-v2-m3 的 Cross-Encoder 重排序（Re-ranking）机制，对初筛结果进行深度的语义交互计算与重新打分，从而最大化最终输入给大模型的上下文精准度，并有效滤除噪声干扰。

(3) 大模型接入与生成约束（提示工程）。系统后端将基于 LangChain 框架接入高性能大语言模型（如 DeepSeek API），打通 RAG 核心链路。针对工程认证工作对严谨性的极高要求，本文专门设计了面向 OBE 理念的提示词（Prompt）模板，强制约束模型仅依据检索召回的上下文进行应答。旨在有效抑制大模型的“幻觉”现象，确保生成内容的真实性与逻辑一致性。

(4) 系统工程化部署与证据溯源实现。在前端展示层面，采用 Vue 框架开发知识

助手的 Web 交互界面，完成系统的整体工程化部署。该模块设计的核心聚焦于“可追溯性”，通过开发证据链可视化功能，确保系统生成的每一条回答均能提供精确的引用链接，支持用户一键跳转至原始文档的对应段落与页码，从而为认证专家的核查工作提供无缝的证据支撑。

1.4.2 预期目标

- 完成原型系统开发：成功搭建一套基于 Advanced RAG 架构的工程教育认证知识助手（Vue + DeepSeek API），支持自然语言流畅交互与私有文档的高效管理。
- 实现高精度知识检索：通过双阶段检索与重排序优化，显著提升系统在处理“课程目标”、“达成度计算”等高频专业问题时的检索准确率（Recall 与 Precision 指标达到预期基准）。
- 确保证据链精准溯源：生成的问答结果必须具备高度的可解释性，实现精准的“证据闭环”，杜绝事实性编造。
- 提升认证业务效率：验证系统在实际业务场景中的可用性，证明其相较于传统人工翻阅方式能大幅缩短信息比对与检索时间，有效赋能教学管理人员高质量完成认证材料的整编工作。

2 相关理论与核心技术基础

2.1 大规模语言模型与提示工程

2.1.1 大语言模型 (LLM) 理论基础

大规模语言模型（Large Language Models, LLM）是构建于 Transformer 架构之上的深度神经网络模型，通过在海量文本语料上进行预训练，展现出卓越的自然语言理解（NLU）与生成（NLG）能力。LLM 的核心机制在于其集成的自注意力机制（Self-Attention），该机制赋予了模型捕捉长距离词项依赖关系的能力，使其能够深入理解复杂的语义结构并在生成文本时保持高度的上下文连贯性[13]。

尽管 LLM 在通用任务中表现优异，但其知识存储依赖于预训练阶段形成的“参数化记忆”。这种模式导致模型存在固有的局限性：一方面，模型无法实时更新预训练截止日期之后的知识，产生“知识滞后”现象；另一方面，在处理专业性极强或长尾领域的知识密集型任务时，模型极易因内蕴知识匮乏而产生“幻觉（Hallucination）”，即生成看似逻辑合理但违背事实或虚假的内容[10]。

2.1.2 提示工程

提示工程是指通过设计、优化和精炼输入给大模型的文本（Prompt），以引导模型展现出特定能力并约束其输出行为的技术范式。在不改变模型权重参数的前提下，提示工程作为连接用户意图与模型生成能力的桥梁，决定了 LLM 在特定应用场景下的表现上限。有效的提示设计通常由指令（Instruction）、上下文背景（Context）和输出约束（Constraint）等要素构成，旨在将模型的通用推理能力锚定在特定的任务框架内。

2.1.3 基于上下文的约束提示与幻觉抑制

在知识问答系统中，缓解模型幻觉的关键技术路径在于基于上下文的约束提示（Context-Augmented Prompting）。其理论核心是将模型的工作模式从“基于检索的生成”转变为“基于给定知识的阅读理解”，即通过将检索到的外部非参数化知识（如专业文档片段）注入到提示词中，为模型提供即时的参考依据[1]。

研究表明，通过以下特定提示策略可以显著抑制幻觉现象：

1. **角色设定（Persona Prompting）**：在提示词中明确设定模型作为专业领域专家（如工程认证专家）的身份，促使模型进入更严谨的推理模式。

2. **上下文注入与指引**：明确告知模型“以下是相关的参考文档”，并将检索到的文本块作为事实边界提供给模型。[1]。

3. **严格负约束（Negative Constraints）**：通过在指令中加入如“仅依据提供的上下文回答”、“如果信息不足，请回答不知道而非自行编造”等排他性约束，强制限制模型的发散性思维，从根本上缓解事实性错误的产生。

这种基于上下文的约束机制能够有效地将 LLM 的推理范围限定在可验证的证据链内，从而大幅降低事实性错误的产生概率，确证输出内容的专业性与真实性。

2.2 检索增强生成（RAG）技术原理

2.2.1 RAG 的基本定义与核心价值

检索增强生成（Retrieval-Augmented Generation, RAG）是一种结合了预训练生成模型（参数化记忆）与外部知识库（非参数化记忆）的混合范式[1-2]。大规模语言模型（LLM）虽然在自然语言理解上表现卓越，但由于其知识隐式存储于静态的权重参数中，面临着显著的局限性：一是“知识滞后”问题，LLM 无法获取训练截止日期之后的实时信息；二是“幻觉（Hallucination）”现象，即模型在处理长尾知识或复杂事实时易生成虚假内容[1-2]。

研究表明，RAG 通过在生成环节前引入检索机制，强制模型依据外部可信证据进行回答，从而有效抑制了事实性错误[1-2]。这种“开卷考试”式的运作模式，不仅增强了回答的准确性，还为模型的决策过程提供了可追溯的证据链，实现了从“黑箱推理”向“透明论证”的转变[1-2]。

2.2.2 RAG 的标准执行范式

根据 Lewis 等人的研究，RAG 的标准处理流程可概括为索引（Indexing）、检索（Retrieval）与生成（Generation）三个核心阶段：

1. **索引阶段（Indexing）**：这是知识库构建的基础。首先对多模态原始文档进行清洗与提取，将其转化为统一的纯文本格式；随后利用文本分割技术将长文档切分为语义完整的文本块（Chunks）；最后通过嵌入模型（Embedding Model）将文本块映射为高维向量，并存储于向量数据库（Vector Database）中，以支持后续的相似度计算[1,6]。

2. **检索阶段（Retrieval）**：当接收到用户查询（Query）时，系统利用相同的嵌入模型将查询请求向量化。通过最大内积搜索（MIPS）或余弦相似度算法，从数据库中匹配出与该查询语义距离最近的 Top-K 个文本块.[2]这一过程实质上是从海量数据中召回最相关的上下文信息。

3. **生成阶段（Generation）**：检索到的文本块与用户的原始查询被共同喂入提示词模板（Prompt Template），引导 LLM 在既定上下文约束下组织语言，生成最终答案[1-2]。在该阶段，参数化记忆与非参数化知识协同工作，确保输出内容既具备自然语言的流畅性，又具备事实的准确性。

2.2.3 技术演进：从 Naive RAG 到 Advanced RAG

随着研究的深入，RAG 技术已从最初的朴素模式（Naive RAG）演进至高级架构（Advanced RAG）[1] 。Naive RAG 主要依赖简单的“检索-阅读”链路，但在实际应用中暴露出检索精度不足、召回内容噪声干扰严重以及 LLM 处理长上下文时易产生“中间丢失（Lost in the Middle）”等痛点[9]。

为克服上述问题，Advanced RAG 引入了更为复杂的优化机制。其核心演进逻辑在于从单一检索转向“初筛-精排”的双阶段检索架构：

- **初筛（Recall）阶段**：系统采用混合检索策略，结合了基于关键词的稀疏检索（如 BM25）与基于语义的稠密向量检索。前者擅长专有名词的精确匹配，后者擅长语义理解，二者的结合显著提升了相关文档的召回率[1-2]。

- **重排序（Re-ranking）阶段**：在初筛阶段召回大量文档块后，引入基于 Cross-Encoder 的重排序模型。重排序器会对召回的文档块与用户问题进行更深层的

语义关联度打分并重新排序，滤除其中的不相关噪声数据。这一机制确保了输入 LLM 的上下文是最具针对性的证据，有效减轻了无关噪声对模型生成的误导[1]。

2.3 向量数据库与检索技术

2.3.1 文本向量化表示（Embedding）原理

在处理大规模非结构化数据时，文本向量化（Embedding）是实现机器理解语义的核心技术。其基本原理是通过深度学习模型将离散的文本符号映射至一个连续的高维向量空间中，生成高维稠密向量（Dense Vector）[6] 。与传统的稀疏表示方法不同，稠密向量能够将语义信息压缩在有限的维度中（通常为 768 或 1024 维），从而有效地捕获词项间的上下文关联与深层语义特征[5-6]。

这种表示方法的优势在于它实现了“语义距离”向“空间距离”的转化。在向量空间中，语义相近的文本块由于具有相似的特征分布，其对应的向量在空间位置上会彼此接近[5,7] 。这种机制不仅解决了关键词匹配无法处理同义词、近义词的局限性，还为后续基于数学度量的知识检索奠定了表征基础。

2.3.2 相似度计算机制

在完成文本的向量化表示后，衡量两个向量在空间中的相关性成为检索的关键。在众多的距离度量指标中，余弦相似度（Cosine Similarity）被广泛应用于自然语言处理任务中[5]。余弦相似度通过计算两个向量之间夹角的余弦值来衡量它们的方向一致性，其取值范围在 [-1, 1] 之间，值越接近 1 则代表两个向量的语义相关性越高，而忽略其绝对模长的差异。

除了余弦相似度外，常见的度量方式还包括欧式距离（L2 Distance）和内积（Inner Product）[5-6]。对于归一化后的向量，这几种度量方式在排序结果上具有等价性。以余弦相似度为例，其数学计算公式如下所示：

$$\text{similarity} = \cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\|\|\mathbf{B}\|} = \frac{\sum_{i=1}^{n} A_i B_i}{\sqrt{\sum_{i=1}^{n} A_i^2}\sqrt{\sum_{i=1}^{n} B_i^2}} \tag{1}$$

通过上述公式，系统能够量化查询向量与知识库中文档向量的匹配程度，并按分值高低进行排序召回[7]。

2.3.3 向量数据库与 ANN 算法

向量数据库（Vector Database, VDB）如 Milvus 和 Chroma，是专为存储、管理和高效检索大规模高维向量而设计的专用系统[6] 。在小规模数据集下，可以使用精确的最邻近搜索（K-Nearest Neighbor, KNN）通过暴力扫描（Brute-force）计算

所有距离。然而，由于向量检索面临“维度灾难”，当数据量达到百万级甚至亿级时，KNN 的时间复杂度 O(nD) 将导致检索延迟无法满足实时应用的需求[8]。

为了在检索速度与精度之间取得平衡，向量数据库普遍采用近似最近邻搜索（Approximate Nearest Neighbor, ANN）算法[8]。ANN 通过预先构建索引结构（如 HNSW 图索引或倒排索引），将搜索范围限制在空间的一个子集中，从而实现毫秒级的响应。

其中，乘积量化（Product Quantization, PQ）是一种极具代表性的有损压缩与索引算法[8]。PQ 的核心思想是将高维空间分解为多个低维子空间的笛卡尔积，并对每个子空间分别进行聚类量化。这种方法不仅大幅压缩了向量的存储空间，还允许系统在不解压原向量的情况下，通过查表操作快速估算近似距离，显著提升了大规模向量库的检索能效[6]。

2.4 工程教育专业认证与 OBE 理念

2.4.1 工程教育专业认证的背景与目的

工程教育专业认证（Engineering Education Accreditation, EAC）是由非政府、非盈利的第三方组织对工程技术领域专业进行的正式认可，旨在评价其教育质量是否达到行业公认的最低合格标准[4]。随着我国正式加入《华盛顿协议》，具有国际实质等效性的专业认证已成为推动高等工程教育改革的关键抓手[3]。认证的核心目的在于进一步提高工程教育质量，增强人才培养对经济社会发展的适应性，并最终实现工程教育的国际互认，提升毕业生的国际竞争力[4]。

2.4.2 成果导向教育（OBE）的核心内涵

工程教育认证遵循“成果导向（Outcome-Based Education, OBE）”、“以学生为中心”和“持续改进”三大核心理念，其中 OBE 理念被视为整个认证体系的灵魂。OBE 指出，教学设计与实施的目标应聚焦于学生通过教育过程最终取得的学习成果（Learning Outcomes），而非单纯的知识积累。

在实践中，OBE 强调“反向设计”原则：由外部需求决定培养目标，由培养目标决定毕业要求，再由毕业要求决定课程体系。其中，“毕业要求”是对学生毕业时应掌握的知识、能力和素质的具体描述，而“课程目标”则是支撑毕业要求的最小执行单元。这种严密的映射关系要求课程体系中的每一门课程必须对实现特定的毕业要求有确定的贡献，从而确保全体学生在完成学业时均能达到预期的顶峰成果。

2.4.3 业务痛点关联：证据链管理与溯源挑战

尽管 OBE 理念提供了严谨的逻辑框架，但在实际的认证业务与自评报告撰写过程中，高校面临着严峻的挑战。认证体系要求专业必须通过“举证”的方式，严谨地回答每一项毕业要求是如何实现的，以及如何评价其实际效果。这意味着认证工作不

仅涉及教学大纲、培养方案等制度性文件，还包含海量的教学过程性文档，形成了一个庞杂且语义耦合极强的非结构化文档体系[3-4]。

在传统的文档管理模式下，由于各条款与证据点之间存在复杂的多对多映射关系，人工进行“毕业要求—课程模块—课程目标”的逻辑校验与证据核查效率极低，且难以确保证据链条的完整性与准确溯源。当专家进行现场考查或审核自评报告时，对“证据链条的高效管理和准确溯源”提出了实时化、精准化的极高要求。这种对海量文档语义理解与证据自动定位的刚性需求，暗示了传统人工治理方式已难以支撑 OBE 理念的深度落地，急需引入智能化手段实现知识的精准检索与可靠证成。

3 知识助手系统需求分析与总体设计

3.1 系统需求分析

工程教育专业认证（EAC）的核心理念是成果导向教育（OBE），其认证过程具有知识密度高、文档类型复杂以及对证据链完整性和溯源精准度要求极高的行业特征。传统的认证工作流程高度依赖人工查阅海量分散的私有文档，极易导致证据链遗漏或断裂，严重影响认证效率和质量。为突破这一业务瓶颈，本系统以解决 EAC 认证工作中的实际痛点为导向，结合大语言模型（LLM）与检索增强生成（RAG）技术，进行详尽的系统需求分析。

3.1.1 功能性需求分析

为构建安全、精准、可追溯的工程认证知识服务平台，有效辅助教学管理人员进行自评报告撰写和材料整编，本系统需满足以下核心功能性需求：

1. **私有文档库管理与解析需求**工程认证工作涉及的私有文档往往篇幅较长且类型复杂（如专业培养方案、教学大纲、课程目标达成度报告、学生试卷及自评报告等）。系统必须具备对这些海量分散的私有文档进行统一管理和高效转化的能力。

   - **多模态复杂文档导入：**系统需支持 PDF、Word 等多模态与多格式文档的批量导入与预处理清洗。
   - **结构化解析与语义切分：**针对传统固定字符数切分（Fixed-size chunking）容易导致表格、跨页段落或“毕业要求指标点”等逻辑条目语义破损的问题，系统需支持基于文档层级特征的结构化解析与语义感知切片（Chunking），提取并保留文档的层级结构信息与完整语境。
   - **向量化存储：**系统需支持将解析后的非结构化文本通过嵌入模型（Embedding）转化为高维向量，并存储于本地私有向量数据库（如 Milvus 或 Chroma）中，将离散文档转化为可被高效访问的知识资产。

2. **智能问答与专业意图理解需求**认证工作参与人员需要通过系统快速获取高度专业化的信息。系统不仅需要具备通用的自然语言处理能力，更需要针对工程教育领域的特定语境进行深度适配。

   - **自然语言交互：**系统需提供友好的 Web 端交互界面，支持用户以自然语言的形式输入查询问题。
   - **专业意图精准理解：**针对通用大模型在处理工程认证特定领域术语时匹配度不高（即长尾与噪声问题），系统需能精准识别并理解“毕业要求指标点”、“课程目标达成度”、“成果导向教育（OBE）”等特定专业术语的语义关联。

3. **证据链可视化与精准溯源需求**工程教育认证工作对“证据链”的完整性与真实性具有极高的监管要求。由于大语言模型存在固有“幻觉”（Hallucination）缺陷，其黑箱推理过程对于需要严格证据支撑的垂直应用场景是不可接受的。因此，系统必须建立严密的证据倒查机制：

   - **引文参考输出：**系统在输出最终回答时，绝不能仅提供单一的总结性文本，必须强制同步输出其参考的引文片段与支撑依据。
   - **特定段落与页码级溯源：**必须赋予系统高度的“可解释性”与“可溯源性”。系统需支持溯源可视化功能，当认证专家或用户点击回答中的引文标注时，系统需能够直接跳转并精准定位至原始文档（如 PDF）的具体页码与特定段落。这一需求是辅助专家无缝进行证据核查、确保证据链闭环的核心支撑。

3.1.2 功能性需求分析

在满足上述业务功能的基础上，系统还需在性能、安全性与可维护性方面达到以下非功能性指标：

1. **准确性与安全性需求**大语言模型在生成过程中存在固有的“幻觉”缺陷，其黑箱推理极易生成看似合理实则错误的内容，这对于需要严格证据支撑的工程认证场景是不可接受的。系统必须通过严格的提示工程（Prompt Engineering）进行约束，确保大模型的回答完全忠实于本地检索到的私有文档，彻底杜绝事实性编造。同时，系统需保障本地化部署架构的数据安全，防止高校核心教务数据的外泄。

2. **系统性能与响应效率需求**为保障知识助手的交互体验，系统整体响应延迟需控制在合理范围内。由于本系统在检索环节采用了复杂度较高的双阶段检索架构（即稠密向量初筛检索与重排序精排机制），且大模型的长文本生成需要一定算

力开销，系统必须在检索高召回率与计算速度之间取得良好平衡，确保端到端的问答延迟能够满足用户的日常流畅使用。

3. **系统的可扩展性与易用性需求**

   - **易用性**：系统需具备友好的 Web 端交互界面（基于 Vue 框架构建），保证页面布局直观、交互操作简便，降低非技术背景教务人员的学习门槛。
   - **可扩展性**：考虑到各专业的培养标准与认证材料每年都会进行滚动更新，系统的底层架构设计必须方便后续私有知识库的动态更新、文档扩容及索引热重载，以长效支撑高校工程教育的持续改进机制。

3.2 系统总体架构设计

1. **数据与存储层 (Data & Storage Layer)**：本层是系统的底层数据底座与物理存储介质，主要负责多源异构数据的持久化管理。系统底层的数据来源主要涵盖工程教育专业认证（EAC）工作中的各类私有多模态复杂文档，如专业培养方案、教学大纲、课程目标达成度报告及学生试卷等（通常涉及 PDF、Word 等格式）。在核心存储组件设计上，系统采用“双轨并行”的混合存储架构：一方面，采用专门的高性能向量数据库（如 Milvus 或 Chroma）来持久化存储经过解析与语义切分后的文本块（Chunks）及其对应的高维稠密向量，从而将海量离散文档转化为可被高效访问的机器可读知识资产；另一方面，系统利用本地文件系统（Local File System）持久化归档原始多模态文档与结构化元数据（Metadata）。这种存储策略不仅支撑了高效的向量近邻搜索，更为后续前端的应用层实现“证据链精准溯源与页码定位”提供了坚实的物理文件支撑。

2. **核心处理层 (Processing Layer)**：本层作为检索增强生成（RAG）架构的引擎中枢，承担着离线私有知识库构建与在线智能检索的双重核心任务。在离线知识库构建阶段，针对工程认证文档长文本、多表格等结构复杂的特征，系统引入了基于文档层级特征的结构化解析与语义感知切块（Semantic Chunking）技术[1]。该方法有效克服了传统固定字符粗粒度切分导致的表格破损与跨页语义断裂问题，最大程度保留了“毕业要求指标点”等核心条款的完整上下文语境。在在线检索机制设计上，本系统全面拥抱 Advanced RAG 理念，构建了高精度的双阶段检索（Dual-stage Retrieval）架构：首阶段利用稠密向量搜索（Dense Retrieval）进行快速初筛，保障大规模私有库检索的广度与高召回率；次阶段引入 bge-reranker-v2-m3 模型作为 Cross-Encoder 进行深度重排序（Re-ranking）精排操作。重排序模型通过细粒度计算文档块与用户查询之间的深度相关性得分，有效滤除初筛阶段引入的无关噪声数据，确切保障最终输入给大模型的上下文证据具有极高的专业匹配度与准确率[1]。

3. **大模型控制层 (Model & Logic Layer)**：本层是整个知识助手的“认知大脑”与逻辑编排控制中心。系统引入了高度模块化的 LangChain 框架进行工作流编排（Workflow Orchestration），实现数据层、处理层模型与外部接口的串联与状态调度。在核心的生成逻辑控制上，本层通过定制化提示工程（Prompt Engineering），设计了契合“成果导向教育（OBE）”理念的严格系统级提示词（Prompt）模板。该模板强制要求大模型将重排序后的高精度本地上下文证据与用户的 Query 进行有机组装，并严格限制其发散性思维，要求生成内容仅来源于检索结果。最终，系统通过对接调用 DeepSeek API 执行可控的文本生成任务。这种生成约束框架不仅赋予了通用大模型处理工程教育特定领域逻辑的能力，更从根本上抑制了其固有的“幻觉”现象，确保了专业问答事实严谨、无编造内容。

4. **应用与交互层 (Application Layer)**：本层是系统直接面向终端用户（如认证专家、高校教务管理人员）的前端展示与操作门户。系统前端基于渐进式 JavaScript 框架 Vue 构建 Web 交互界面，注重布局的直观性与非技术人员的易用性。应用层重点封装了两大核心业务模块：一是“多轮自然语言问答”模块，支持用户在维护历史对话上下文的情境下，以自然、流畅的口语化方式对 EAC 繁杂指标和课程目标等问题进行深度追问与探索交互；二是“证据链可视化溯源”模块（本系统的核心工程亮点），该模块承接底层向量元数据与文件存储映射，在渲染 DeepSeek 生成的最终答案时，同步输出带标号的引文参考标注。用户仅需点击对应的引文标签，Web 界面即可实现文档分屏联动，直接跳转并精准定位（包含引文高亮与具体页码跳转）到原始 PDF 文档的对应段落。此举赋予了模型回答高度的“可解释性”与“可溯源性”，完美契合工程认证业务中对材料严密互证与证据链闭环的极高监管要求。

3.3 核心业务流程设计

4 核心模块设计与对比实验分析

4.1 复杂结构文档解析与精细化切块策略

4.2 领域知识向量化与 Embedding 模型选型

为了验证不同 Embedding 模型在工程认证领域的表现，本文构建了包含 50 个问答对的测试集，并进行了对比实验。实验结果如表 1 所示：

表 1: 不同 Embedding 模型在工程认证测试集上的检索性能对比

模型名称	Hit Rate @ 3	MRR @ 5
text2vec-chinese (基线)	0.68	0.52
BGE-large-zh-v1.5	0.85	0.76
text-embedding-3	**0.89**	**0.81**

4.3 混合检索与重排序（Re-ranking）机制

4.4 提示工程设计与生成约束

5 系统实现与整体性能评测

5.1 开发环境与系统部署

5.2 核心功能模块实现与界面展示

5.3 端到端系统整体性能评估

6 总结与展望

6.1 全文工作总结

6.2 系统局限性与未来展望

参考文献

[1] GAO Y, XIONG Y, GAO X, et al. Retrieval-Augmented Generation for Large Language Models: A Survey[M/OL]. arXiv, 2024[2025-11-04]. http://arxiv.org/abs/2312.10997. DOI: 10.48550/arXiv.2312.10997.

[2] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[M/OL]. arXiv, 2021[2025-11-10]. http://arxiv.org/abs/2005.11401. DOI: 10.48550/arXiv.2005.11401.

[3] 李志义. 解析工程教育专业认证的成果导向理念[J/OL]. 中国高等教育, 2014(17): 7-10[2025-11-10]. https://kns.cnki.net/KCMS/detail/detail.aspx?dbcode=CJFQ&dbname=CJFD2014&filename=ZGDJ201417005.

[4] 林健. 工程教育认证与工程教育改革和发展[J/OL]. 高等工程教育研究, 2015(2): 10-19[2025-11-10]. https://kns.cnki.net/KCMS/detail/detail.aspx?dbcode=CJFQ&dbname=CJFDLAST2015&filename=GDGJ201502003.

[5] TAIPALUS T. Vector database management systems: Fundamental concepts, use-cases, and current challenges[J/OL]. Cognitive Systems Research, 2024, 85: 101216[2025-11-10]. http://arxiv.org/abs/2309.11322. DOI: 10.1016/j.cogsys.2024.101216.

[6] MA L, ZHANG R, HAN Y, et al. A Comprehensive Survey on Vector Database: Storage and Retrieval Technique, Challenge[M/OL]. arXiv, 2025[2025-11-10]. http://arxiv.org/abs/2310.11703. DOI: 10.48550/arXiv.2310.11703.

[7] 孙雨生, 曾俊皓. 向量数据库及其应用研究[J/OL]. 科技情报研究, 2024, 6(4): 11-24[2025-11-10]. https://doi.org/10.19809/j.cnki.kjqbyj.2024.04.002.

[8] JéGOU H, DOUZE M, SCHMID C. Product Quantization for Nearest Neighbor Search[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2011, 33(1): 117-128[2025-11-10]. https://ieeexplore.ieee.org/document/5432202. DOI: 10.1109/TPAMI.2010.57.

[9] LUO K, LIU Z, ZHANG P, et al. Does RAG Really Perform Bad For Long-Context Processing?[M/OL]. arXiv, 2025[2025-11-10]. http://arxiv.org/abs/2502.11444. DOI: 10.48550/arXiv.2502.11444.

[10] 张丽静, 杜冬梅, 刘庆芳, 等. 基于 LLM 和 RAG 的中邮网院智能客服系统研究[J/OL]. 邮政研究, 2024, 40(4): 66-72[2025-11-10]. https://doi.org/10.13955/j.yzyj.2024.04.11.07.

[11] 冯腾发, 蒋耀宇, 陈浩杰, 等. RAG 知识库在低资源领域知识问答中的应用[J/OL]. 通讯世界, 2025, 32(9): 21-23[2025-11-10]. https://kns.cnki.net/KCMS/detail/detail.aspx?dbcode=CJFQ&dbname=CJFDLAST2025&filename=TXSJ202509007.

[12] 孙如玉, 齐正, 张云贵, 等. HSR-RAG: 面向钢铁材料国家标准的层级语义递归 RAG[J/OL]. 冶金自动化, 2025, 49(5): 87-96[2025-11-10]. https://kns.cnki.net/KCMS/detail/detail.aspx?dbcode=CJFQ&dbname=CJFDAUTO&filename=YJZH202505009.

[13] ZHAO Y, LIN M, TANG H, et al. Merino: Entropy-driven Design for Generative Language Models on IoT Devices[M/OL]. arXiv, 2025[2025-11-10]. http://arxiv.org/abs/2403.07921. DOI: 10.48550/arXiv.2403.07921.